Hlboké neurónové siete 2026

Projekt č. 2

V projekte 2 budete vytvárať CNN, ViT a hybridné modely pre úlohy rozpoznávania na datasetoch tvárí, gest, hlasových povelov, medicínskych dát, atď. Na úlohu navrhnite viacero typov modelov, čo najlepšou úspešnosťou. Pre vyhodnotenie úspešnosti klasifikácie realizujte 5 trénovaní. Pre klasifikáciu do dvoch tried vypočítajte aj senzitivitu a špecificitu. Na trénovanie modelov použite nasledovné vybrané datasety. Je možné použiť aj iné datasety z oblasti robotiky a medicíny po dohode s vyučujúcim. Dataset náhodne rozdeľte v pomere 70% dát na trénovanie, 15% dát na validáciu a 15% dát na testovanie. (ak nie sú data rozdelené). Neurónové modely otestujte na testovacích dátach. Pre jednotlivé modely zobrazte kontingenčné tabuľky. Modely porovnajte na základe metrík úspešnosť (accuracy), presnosť (precision), senzitivita (recall). Ak je možné kvalitu najlepšieho modelu reálne otestujte na kamere (mikrofóne) a dotrénujte model pre zlepšenie výsledkov na kamere. Pre vybrané testovacie vzorky vykonajte vizualizáciu rozhodovania modelov. (napr. GradCAM metóda)

Skupina 1: Kontrola nasadeného rúška

- Rozpoznávanie dobre nasadeného rúška – 2 skupiny (dobre nasadené, zle nasadené) alebo 3 skupiny (bez rúška, zle nasadené, dobre nasadené) https://github.com/cabani/MaskedFace-Net. Porovnať rôzne modely (aspoň 3), najlepší model aplikovať na kameru a urobiť testovanie natrénovaného modelu na správne nasadené rúško.

Skupina 2: Hlasové povely

- Rozpoznávanie hlasových povelov zo zvukových nahrávok – 8 skupín povelov (go, left, right, stop, up, down, on, off). Porovnať rôzne modely (Raw-CNN, Raw-CNN-LSTM. Spect-CNN). Aplikovať najlepší model na mikrofón a urobiť testovanie CNN na naučené povely. Zohľadniť aj šum pozadia (prostredia). (Dataset: https://www.kaggle.com/datasets/mok0na/speech-commands-v002)

Skupina 3: Stavy tváre

- Rozpoznávanie natočenia tváre z RGB obrazu – 4 skupiny (LeftProfile, LightOn, RightProfile, OcclusionPaper). Aplikovať aspoň 3 CNN alebo ViT modely, vybrať najlepší a aplikovať na kameru a urobiť testovanie CNN na natočenie tváre.

- Rozpoznávanie gest tváre z RGB obrazu – 5 skupín (Neutral, OcclusionEyes, OcclusionMouth, OpenMouth, Smile). Aplikovať aspoň 3 CNN alebo ViT modely, vybrať najlepší a aplikovať na kameru a urobiť testovanie CNN na gestá tváre.
- (https://drive.google.com/drive/folders/1YwOCplpXusQXr7d9wsS7kTb9TGJAt5fW?usp=drive_link)

Skupina 4: Gestá ASL 1

- Rozpoznávanie gest ruky z RGB obrazu – 10 skupín (jednotlivé gestá). Aplikovať aspoň 3 CNN alebo ViT modely, vybrať najlepší a aplikovať na kameru a urobiť testovanie CNN na jednotlivé gestá.
- Rozpoznávanie gest ruky z hĺbkovej mapy – 10 skupín (jednotlivé gestá) (Aplikovať aspoň 3 CNN alebo ViT modely)
- (https://drive.google.com/drive/folders/1mpRo653YGYd4iuB-1t5sxog7rBnpaNob?usp=drive_link)

Skupina 5: Gestá ASL 2

- Aplikovať aspoň 3 CNN alebo ViT modely, vybrať najlepší a aplikovať na kameru a urobiť testovanie CNN na jednotlivé gestá.
- Rozpoznávanie gest ruky z hĺbkovej mapy – 10 skupín (jednotlivé gestá) (Aplikovať aspoň 3 CNN alebo ViT modely)
- (https://drive.google.com/drive/folders/1UDefZEX1hMszVGkDu04sFOX3yu9altu9?usp=drive_link)

Skupina 6: Defekty 1

- Rozpoznávanie defektov (jám) na ceste - 2 skupiny (Ok, defect) (CNN a ViT, porovnať 3 modely) (https://drive.google.com/drive/folders/1d3atNCQK9POrsjQJiVZ6M8HoPEfCaTn6?usp=drive_link)
- Kontrola kvality podložiek – 5 skupín (Ok, 4 typy defektov) (CNN – porovnať 3 modely) (https://drive.google.com/drive/folders/1PVE357M-8uburXtl5kFwjo_nowSup1Xx?usp=drive_link)

Skupina 7: Defekty 2

- Kontrola kvality zvarov kamery – 4 skupiny (Ok, 2025-kráterový lunker, 510-diera, 500-poškodený povrch zvaru) (CNN a ViT, porovnať 3 modely) (https://drive.google.com/drive/folders/1SUivIX-uDGs74XNegNQp95wvQ78C5DIe?usp=drive_link)
- Kontrola kvality obrobkov - 2 skupiny (Ok, defect) (Autoenkóder a FCDD) (originál data - https://www.kaggle.com/datasets/ravirajsinh45/real-life-industrial-dataset-of-casting-product/data)

Skupina 8: Defekty 3

- Klasifikácia defektov dataset NEU-DET (6 typov defektov) (CNN a ViT, porovnať 3 modely) (https://www.kaggle.com/datasets/rdsunday/neu-urface-defect-database)
- Kontrola kvality pneumatík - 2 skupiny (Ok, defect) (CNN a ViT, porovnať 3 modely)

(https://drive.google.com/drive/folders/1EO9dj8x2OM21ZSBs8xlqTLSzH-FDLOBB?usp=drive_link)

Skupina 9: Detekcia ľudských činností

- Rozpoznávanie ľudských činností z videa (aspoň dve činnosti), ktoré je možné pred kamerou názorne otestovať (napr. pitie a jedenie) (napr. dataset HMDB51). Použite aspoň dve metódy (CNN+SVM, CNN+LSTM, ...). Najlepšiu metódu aplikujte na kameru.

Skupina 10: Detekcia anomálii – EKG signály

- Na datasete ECG navrhnite viaceré modely pre rozpoznávanie anomálií pri elektrickej aktivite srdca. Použite nasledovné dvojtriedne modely (SVM, MLP, 1D-CNN, LSTM) a nasledovné jednotriedne modely (autoenkóder, One-Class SVM, Isolation Forest) (dataset ECG - https://www.kaggle.com/datasets/devavratatripathy/ecg-dataset/data).

Skupina 11:

- Rozpoznávanie Diabetickej Retinopatie (DR) na fundus snímkach očného pozadia. – 5 skupín (No DR – bez DR, Mild – mierna NDR, Moderate – stredne závažná NDR, Severe - závažná NDR, Proliferative DR – Proliferatívna retinopatia). Porovnajte aspoň 3 modely. Najlepší model aplikujte aj na klasifikáciu do 2 skupín (Normal, Positive) . Dataset: (https://www.kaggle.com/datasets/sampathsaivamsimatha/diabetic-rethinopathy-dataset-new)

Skupina 12:

- Rozpoznávanie nálezov na hrubom čreve. (8 skupín nálezov) Dataset KVASIR (https://www.kaggle.com/datasets/meetnagadia/kvasir-dataset).
- (https://drive.google.com/drive/folders/1XJiAKuaDOcOyz5baznfUCP-VB2re3J8s?usp=drive_link)
- Rozpoznávanie ochorenie Aizheimer na MRI obrazoch – 2 skupiny (normal, positive) (https://drive.google.com/drive/folders/1ARzPYGbM_oUccYpTV9js5bKHGwuCYBTg?usp=drive_link)

Výsledky projektu zaznamenajte do dokumentácii a spolu s programami vložte do AISu do 12. týždňa.