SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Klasifikácia obrazov jedál pomocou transferového učenia

HNS – Projekt č. 1

2025/2026 Bc. Dominik Kupec

Obsah

Úvod **3**

1 Dáta a ich spracovanie **4**

1.1 Dataset 4

1.2 Rozdelenie na trénovaciu, validačnú a testovaciu množinu 4

1.3 Predspracovanie a augmentácia 4

2 Model M1 – CNN ResNet50 **5**

2.1 Parametre trénovania 5

2.2 Priebeh trénovania a výsledky na testovacích dátach 5

2.3 Vizualizácia rozhodovania – GradCAM 7

3 Vplyv augmentácie trénovacích dát **9**

4 Vplyv postupného rozmrazovania vrstiev **11**

5 Zhrnutie výsledkov **15**

6 Implementácia **16**

Záver **17**

Úvod

Cieľom projektu je porovnať trénovanie vybraných architektúr konvolučných neurónových sietí, vizuálnych transformerov a hybridných modelov pri riešení úlohy klasifikácie obrazu pomocou transferového učenia (transfer learning). Táto dokumentácia pokrýva prvú fázu projektu – model **M1** (CNN ResNet50 s transferovým učením) a dva povinné doplnkové experimenty, ktoré zadanie vyžaduje aspoň pre jeden model:

- vplyv augmentácie trénovacích dát na úspešnosť klasifikácie,
- vplyv postupného rozmrazovania vrstiev (*gradual unfreezing*) predtrénovanej siete oproti trénovaniu iba novej výstupnej vrstvy.

Ako dataset bol použitý výber z databázy **Food-101** – klasifikácia obrazov jedál. Z pôvodných 101 tried bolo vybraných 15 najviac vizuálne odlíšiteľných tried (napr. dumplings, lasagna, pizza, steak, waffles), každá s 1000 obrázkami, spolu 15 000 obrázkov. Dataset bol náhodne rozdelený v pomere 80/10/10 na trénovaciu, validačnú a testovaciu množinu (12 000/1 500/ 1 500 obrázkov), pri zachovaní rovnakého zastúpenia tried vo všetkých troch množinách.

Pre model M1 boli spustené tri nezávislé trénovania (rovnako ako pri doplnkových experimentoch) a výsledky boli štatisticky vyhodnotené (priemer a smerodajná odchýlka). Pre najlepší beh je zobrazený priebeh trénovania (Loss a Accuracy na trénovacích a validačných dátach), na testovacích dátach bola vyčíslená presnosť (Accuracy), presnosť (Precision) a senzitivita (Recall), spolu s kontingenčnou tabuľkou. Pre vybrané testovacie vzorky bola vykonaná vizualizácia rozhodovania siete metódou GradCAM.

1 Dáta a ich spracovanie

1.1 Dataset

Pre klasifikáciu bol použitý výber z databázy jedál **Food-101** (zdroj Kaggle, `food41`). Pôvodná databáza obsahuje 101 tried, podľa zadania („použiť minimálne 10 tried, ktoré sú najviac zastúpené“) bolo vybraných **15 tried**: *beef_tartare, chicken_wings, cup_cakes, donuts, dumplings, french_fries, greek_salad, hot_dog, lasagna, lobster_bisque, pancakes, panna_cotta, pizza, steak, waffles*. Každá trieda obsahuje presne 1000 obrázkov, spolu **15 000 obrázkov**, dataset je teda dokonale vyvážený.

1.2 Rozdelenie na trénovaciu, validačnú a testovaciu množinu

Dataset bol náhodne rozdelený v pomere **80 % / 10 % / 10 %** (stratifikovane podľa triedy, aby malo každé jedlo rovnaké zastúpenie vo všetkých troch množinách):

Tabuľka 1: Veľkosť jednotlivých množín

Množina	Obrázkov spolu	Obrázkov na triedu
Trénovacia	12 000	800
Validačná	1 500	100
Testovacia	1 500	100

Rozdelenie je uložené v `data_split/manifest.csv` s pevne daným náhodným semienkom, takže je reprodukovateľné a testovacie dáta neboli pri žiadnom trénovaní ani ladení modelu použité.

1.3 Predspracovanie a augmentácia

Všetky obrázky sú pred vstupom do siete zmenšené a orezané na 224×224 px a normalizované strednou hodnotou a smerodajnou odchýlkou ImageNet datasetu (keďže backbone je naň predtrénovaný). Pre validačnú a testovaciu množinu sa používa iba táto deterministická transformácia.

Pre trénovaciu množinu je k dispozícii augmentovaná verzia (`RandomResizedCrop`, horizontálne preklopenie, náhodná rotácia $\pm 15°$, farebný jitter, náhodný autokontrast a `RandomErasing`), ktorá sa použije pri základnom modeli M1 a je vypnutá pri ablácii bez augmentácie (kapitola 3).

2 Model M1 – CNN ResNet50

Ako architektúra CNN bol zvolený **ResNet50**, predtrénovaný na ImageNet (váhy `IMAGENET1K_V2`). Výstupná plne prepojená vrstva bola nahradená novou lineárnou vrstvou s 15 výstupmi (podľa počtu tried). V základnej konfigurácii je celý backbone **zamrznutý** (trénuje sa iba nová výstupná vrstva) – ide o tzv. *linear probing*, referenčnú konfiguráciu, voči ktorej sa v kapitole 4 porovnáva postupné rozmrazovanie vrstiev.

2.1 Parametre trénovania

Rovnaké parametre trénovania sa používajú vo všetkých troch M1 konfiguráciách (základná, bez augmentácie, postupné rozmrazovanie), aby boli výsledky priamo porovnateľné:

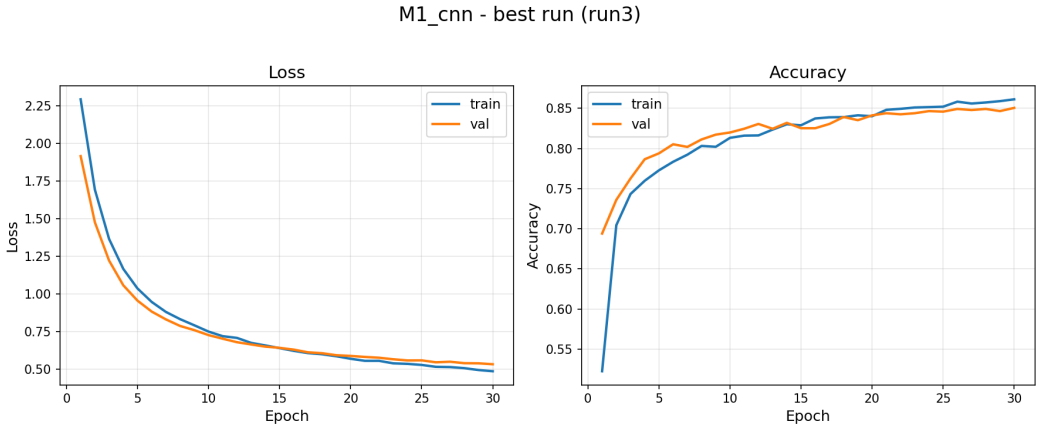
Tabuľka 2: Parametre trénovania M1

Parameter	Hodnota
Optimalizátor	AdamW
Learning rate	3×10^{-4}
Weight decay	1×10^{-4}
Veľkosť dávky	128
Počet epoch	30
Strata	CrossEntropyLoss
Presnosť výpočtu	zmiešaná (AMP, float16)
Počet nezávislých behov	3

Každá konfigurácia bola spustená **3-krát** s odlišným náhodným semienkom (inicializácia váh novej vrstvy, poradie dávok), aby bolo možné štatisticky vyhodnotiť priemer a rozptyl výsledkov.

2.2 Priebeh trénovania a výsledky na testovacích dátach

Obr. 1 zobrazuje priebeh trénovania (Loss a Accuracy na trénovacích a validačných dátach) najlepšieho z troch behov. Krivky rastú plynulo bez známok preučenia – keďže sa trénuje iba výstupná lineárna vrstva nad zamrznutým, bohato predtrénovaným backbonom, model má relatívne malú kapacitu vzhľadom na veľkosť trénovacej množiny.

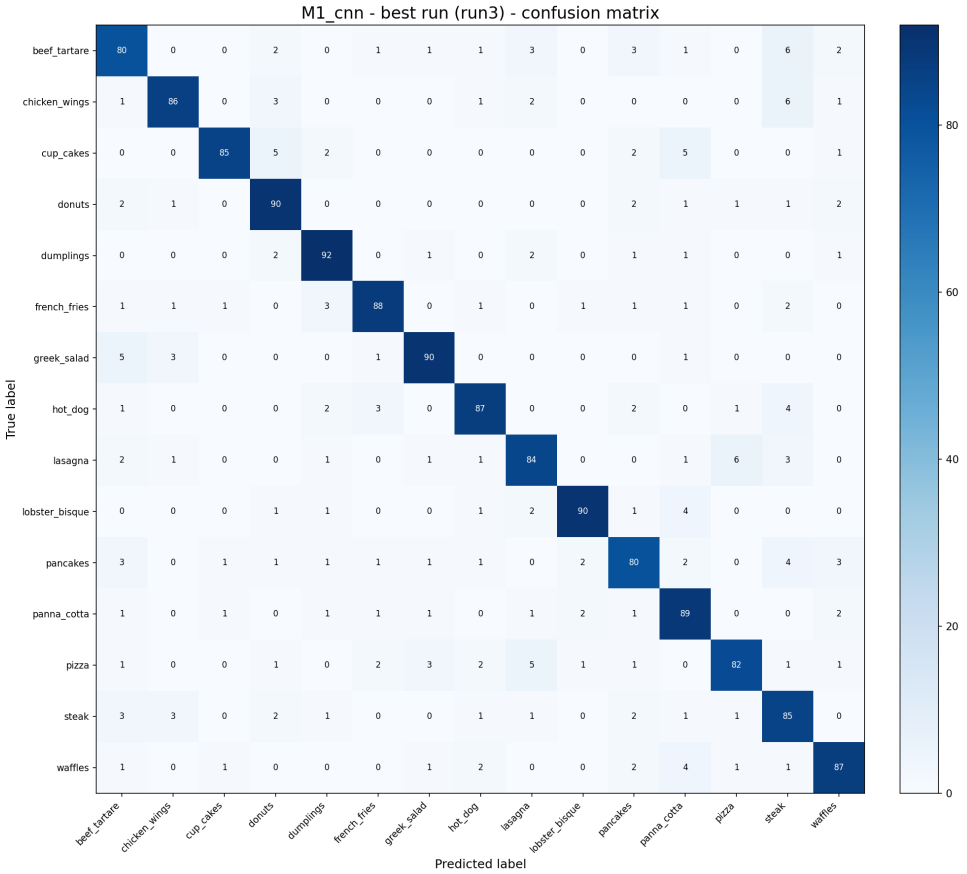


Obr. 1: M1 – priebeh trénovania najlepšieho behu (Loss a Accuracy)

Tabuľka 3: M1 – testovacie metriky (priemer ± smerodajná odchýlka z 3 behov)

Metrika	Hodnota
Accuracy	86,13 ± 0,16 %
Precision	86,43 ± 0,15 %
Recall	86,13 ± 0,16 %
F1	86,19 ± 0,16 %

Nízka smerodajná odchýlka (rádovo desatiny percenta) naprieč tromi behmi ukazuje, že výsledok je stabilný a nezávisí výrazne od náhodnej inicializácie – očakávané pri lineárnom probingu nad zamrznutým, deterministicky predtrénovaným backbonom.

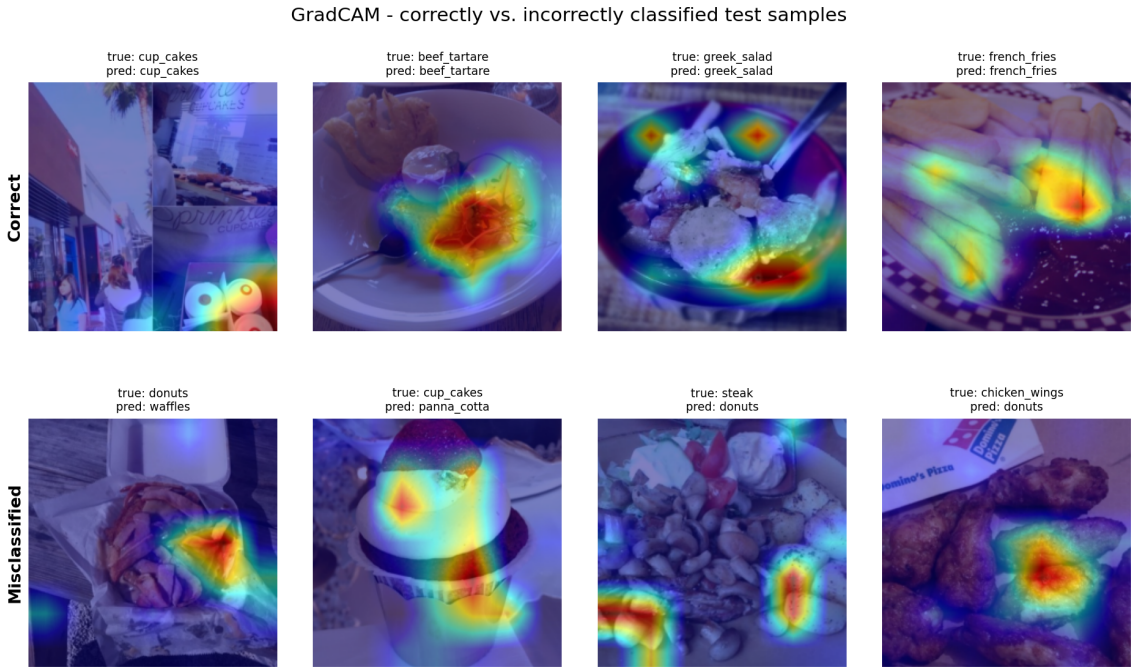


Obr. 2: M1 – kontingenčná tabuľka najlepšieho behu (testovacie dáta)

Z kontingenčnej tabuľky (Obr. 2) je vidieť, že najviac zámen vzniká medzi vizuálne podobnými jedlami – napr. *steak* a *beef_tartare* (oba obsahujú surové/tmavé mäso), alebo *pancakes* a *waffles* (podobná farba a textúra povrchu). Naopak triedy s výrazným, jedinečným vzhľadom (*greek_salad*, *lobster_bisque*) sú klasifikované takmer bezchybne.

2.3 Vizualizácia rozhodovania – GradCAM

Pre vybrané testovacie vzorky (správne aj nesprávne klasifikované) bola vykonaná vizualizácia rozhodovania siete metódou **GradCAM**, aplikovanou na posledný konvolučný blok backbonu (`layer4`). Mapa zvýrazňuje oblasti obrazu, ktoré najviac prispeli k predikovanej triede.

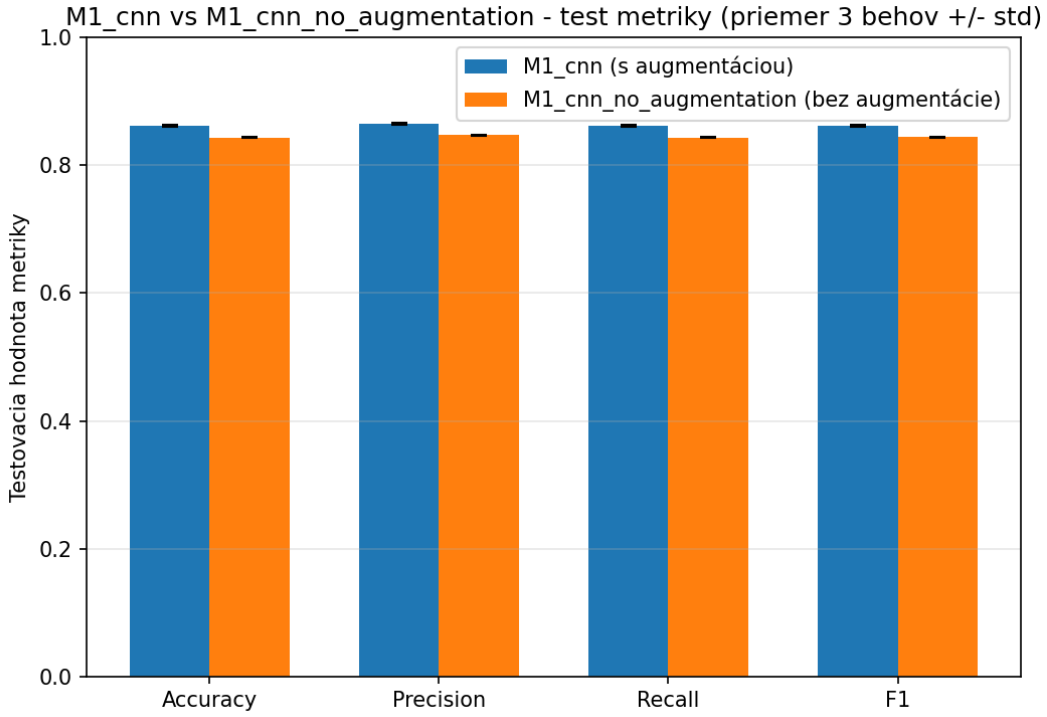


Obr. 3: M1 – GradCAM vizualizácia na správne (hore) a nesprávne (dole) klasifikovaných testovacích vzorkách

Pri správne klasifikovaných vzorkách sa aktivácia sústreďuje priamo na jedlo (typický tvar, textúra povrchu), pri nesprávne klasifikovaných vzorkách sieť často reaguje na okrajové alebo pozadové prvky (tanier, príloha, osvetlenie), prípadne sa sústreďuje na časť obrazu, ktorá je vizuálne zameniteľná s inou triedou – čo zodpovedá zámenám pozorovaným v kontingenčnej tabuľke.

3 Vplyv augmentácie trénovacích dát

Podľa zadania („aspoň pre jeden model ukážte vplyv augmentácie na úspešnosť klasifikácie“) bola pri modeli M1 porovnaná trénovacia konfigurácia s augmentáciou (`M1_cnn`) a bez augmentácie (`M1_cnn_no_augmentation`) – ostatné parametre trénovania (Tabuľka 2) zostali nezmenené.

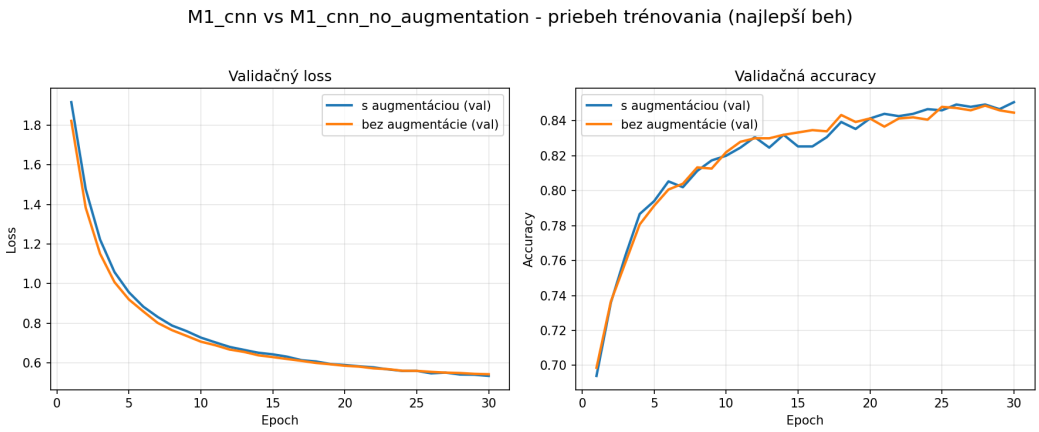


Obr. 4: Vplyv augmentácie – testovacie metriky (priemer 3 behov ± std)

Tabuľka 4: Vplyv augmentácie – testovacia accuracy (priemer ± std z 3 behov)

	S augmentáciou	Bez augmentácie
Accuracy	**86,13 ± 0,16 %**	84,31 ± 0,06 %
Precision	**86,43 ± 0,15 %**	84,67 ± 0,08 %
Recall	**86,13 ± 0,16 %**	84,31 ± 0,06 %
F1	**86,19 ± 0,16 %**	84,38 ± 0,07 %

Augmentácia trénovacích dát zvýšila testovaciu accuracy o približne **1,8 percentuálneho bodu** (86,13 % oproti 84,31 %), pričom rozdiel je oveľa väčší než smerodajné odchýlky oboch konfigurácií (0,16 a 0,06 p. b.) – ide teda o systematický, nie náhodný efekt.



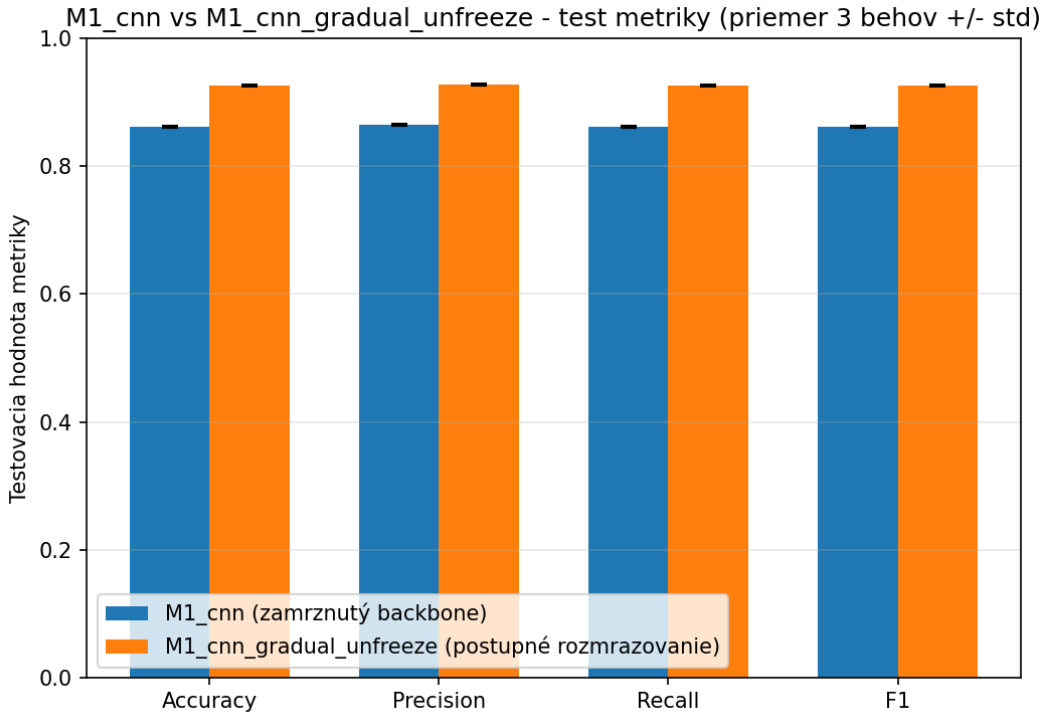
Obr. 5: Vplyv augmentácie – priebeh validačného Loss a Accuracy najlepšieho behu

Zaujímavé je, že priebeh *validačnej* accuracy a loss (Obr. 5) je počas trénovania pri oboch konfiguráciách takmer identický – rozdiel sa prejaví až na testovacích dátach. Vysvetlenie je konzistentné s tým, že sa trénuje iba malá výstupná vrstva nad zamrznutým backbonom: model sa v žiadnej z konfigurácií výrazne nepreučí ani za 30 epoch, augmentácia teda nefunguje ako klasická regularizácia proti preučeniu, ale robí naučenú reprezentáciu robustnejšou voči variáciám vstupu (uhol, mierka, osvetlenie, orezanie), ktoré sa objavujú v testovacej množine, ale validačná množina ich v danom behu nemusí dostatočne pokrývať.

4 Vplyv postupného rozmrazovania vrstiev

Podľa zadania („aspoň pre jeden model realizujte postupné rozmrazovanie vrstiev predtrénovanej siete“) bola pri modeli M1 porovnaná základná konfigurácia so **zamrznutým backbonom** (`M1_cnn`) oproti konfigurácii s **postupným rozmrazovaním** (`M1_cnn_gradual_unfreeze`).

Rozmrazovanie prebieha v poradí `layer4 -> layer3 -> layer2 -> layer1` (od najvyššej, najviac úlohovo-špecifickej vrstvy k najnižšej, najviac všeobecnej), rovnomerne rozložené cez 30 epoch – prvá vrstva (`layer4`) sa rozmrazí po približne 6 epochách (po „zahriatí“ novej výstupnej vrstvy), posledná (`layer1`) tesne pred koncom trénovania. Novo rozmrazené parametre sa pridajú do optimalizátora s rovnakým learning rate ako zvyšok siete.

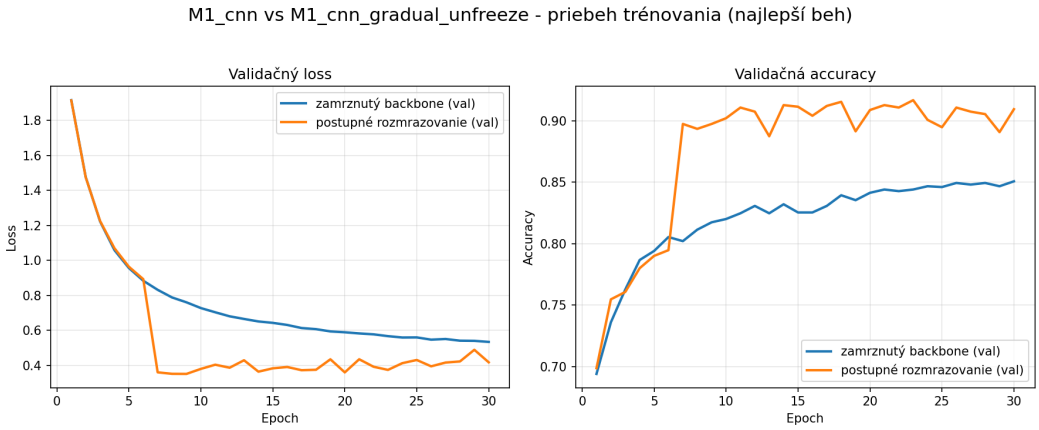


Obr. 6: Vplyv postupného rozmrazovania – testovacie metriky (priemer 3 behov ± std)

Tabuľka 5: Vplyv postupného rozmrazovania – testovacia accuracy (priemer ± std z 3 behov)

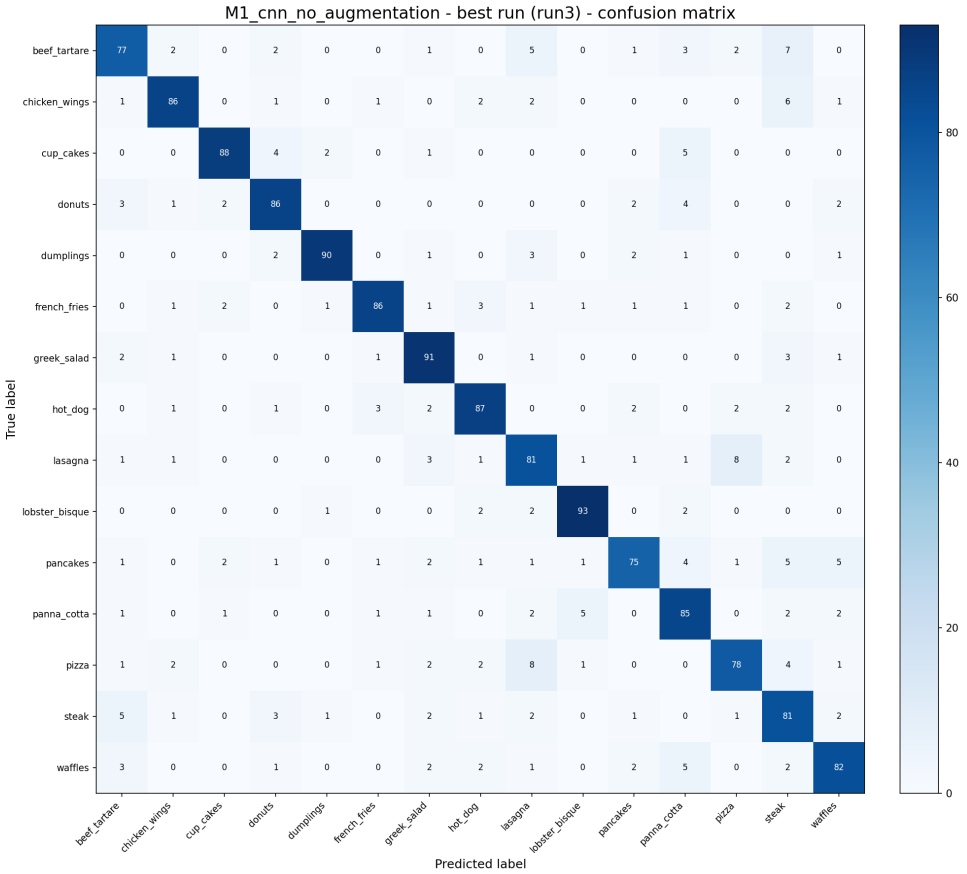
	Zamrznutý backbone	Postupné rozmrazovanie
Accuracy	86,13 ± 0,16 %	**92,60 ± 0,19 %**
Precision	86,43 ± 0,15 %	**92,75 ± 0,15 %**
Recall	86,13 ± 0,16 %	**92,60 ± 0,19 %**
F1	86,19 ± 0,16 %	**92,61 ± 0,17 %**

Postupné rozmrazovanie zvýšilo testovaciu accuracy o **6,5 percentuálneho bodu** (92,60 % oproti 86,13 %) – výrazne väčší efekt než pri augmentácii. Umožnenie doučiť aj vyššie konvolučné vrstvy backbonu (nie len novú lineárnu hlavu) dovoľuje sieti prispôsobiť si naučené príznaky špecificky pre rozlišovanie jedál, namiesto použitia všeobecných príznakov naučených na ImageNet.

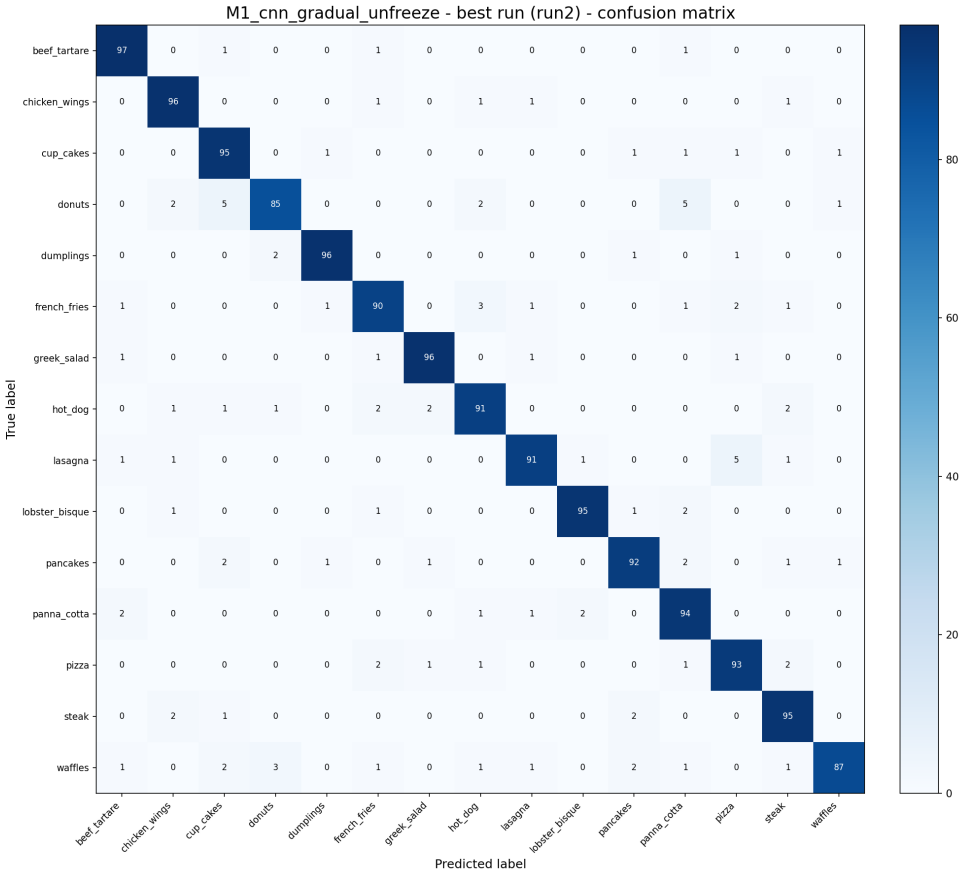


Obr. 7: Vplyv postupného rozmrazovania – priebeh validačného Loss a Accuracy najlepšieho behu

Priebeh validačnej accuracy (Obr. 7) ukazuje jasný skok približne na 7. epoche – presne vtedy, keď sa rozmrazí `layer4`. Loss a accuracy sa dovtedy vyvíjajú takmer identicky ako pri zamrznutom backbone, po rozmrazení prvej vrstvy nasleduje výrazný pokles validačného lossu (z ∼0,9 na ∼0,35) aj skok accuracy (z ∼80 % na ∼90 %), po ktorom sa krivka ustáli. Ďalšie rozmrazovanie vrstiev (`layer3`, `layer2`, `layer1`) už prináša len malé zlepšenie – rozhodujúci je práve prechod z „iba nová hlava“ na „doučenie poslednej konvolučnej vrstvy“, keďže tá obsahuje najviac úlohovo-špecifické príznaky.



Obr. 8: M1 bez augmentácie – kontingenčná tabuľka najlepšieho behu (testovacie dáta)



Obr. 9: M1 s postupným rozmrazovaním – kontingenčná tabuľka najlepšieho behu (testovacie dáta)

5 Zhrnutie výsledkov

Tabuľka 6: Súhrnné porovnanie všetkých troch konfigurácií M1 (priemer ± std z 3 behov)

Konfigurácia	Accuracy	Precision	Recall	Čas trénovania
M1 (základná, s augmentáciou)	86,13 ± 0,16 %	86,43 ± 0,15 %	86,13 ± 0,16 %	0:29:50
M1 bez augmentácie	84,31 ± 0,06 %	84,67 ± 0,08 %	84,31 ± 0,06 %	0:27:14
M1 s postupným rozmrazovaním	**92,60 ± 0,19 %**	**92,75 ± 0,15 %**	**92,60 ± 0,19 %**	0:44:10

Oba doplnkové experimenty potvrdili očakávaný smer efektu – augmentácia aj postupné rozmrazovanie vrstiev zvyšujú testovaciu úspešnosť, pričom rozmrazovanie vrstiev backbonu má na tomto datasete podstatne väčší vplyv (6,5 p. b.) než augmentácia dát (1,8 p. b.). To naznačuje, že hlavným limitujúcim faktorom základnej konfigurácie M1 nie je preučenie (ktoré rieši augmentácia), ale nedostatočná kapacita samotného trénovaného lineárneho klasifikátora nad všeobecnými, na ImageNet naučenými príznakmi.

6 Implementácia

Projekt je napísaný v Pythone (PyTorch, torchvision, pytorch-grad-cam, pandas, matplotlib, scikit-learn). Kód v priečinku `src/` je štruktúrovaný takto:

Tabuľka 7: Štruktúra zdrojových súborov

Súbor	Obsah
`config.py`	centrálna konfigurácia (cesty, split, hyperparametre)
`data_preprocessing/split_dataset.py`	rozdelenie datasetu 80/10/10
`data_preprocessing/dataset.py`	`Dataset`/`DataLoader` z manifestu
`data_preprocessing/transforms.py`	augmentované a plain transformácie
`models/M1_CNN_ResNet50.py`	architektúra M1 (ResNet50 + postupné rozmrazovanie)
`engine.py`	spoločná tréningová/evaluačná slučka pre všetky modely
`experiment.py`	3 behy, ukladanie metrík, grafov a checkpointov
`evaluation.py`	výpočet metrík, kontingenčná tabuľka, štatistiky behov
`plots.py`	grafy priebehu trénovania a kontingenčných tabuliek
`gradcam.py`	GradCAM vizualizácia
`M1_ResNet50_Train/train_m1.py`	trénovanie základnej M1 konfigurácie
`M1_ResNet50_Train/train_m1_no_augmentation.py`	ablácia bez augmentácie
`M1_ResNet50_Train/train_m1_gradual_unfreeze.py`	ablácia s postupným rozmrazovaním
`M1_ResNet50_Train/gradcam_m1.py`	GradCAM pre najlepší beh M1
`summarize_results.py`	súhrnná tabuľka všetkých natrénovaných modelov
`compare_M1_experiments.py`	porovnanie augmentácie a rozmrazovania voči základnej M1

Všetky tri konfigurácie M1 využívajú tú istú tréningovú/evaluačnú infraštruktúru (`engine.py`, `experiment.py`), líšia sa iba jedným parametrom (`augment_train` alebo `unfreeze_schedule`), takže výsledky sú priamo porovnateľné a rozdiely v úspešnosti možno pripísať výlučne skúmanému faktoru. Pre každý beh sa do `Results/<konfigurácia>/run<N>/` ukladá kompletná história trénovania (`history.csv`), checkpoint najlepšieho modelu, kontingenčná tabuľka (CSV aj PNG) a graf priebehu trénovania; na úrovni `Results/<konfigurácia>/` potom súhrn troch behov (`summary.json`) a grafy pre najlepší beh.

Záver

Model M1 (ResNet50, transferové učenie) dosiahol v základnej konfigurácii (zamrznutý backbone, augmentácia trénovacích dát) testovaciu accuracy **86,13 %** na 15-triednej klasifikácii jedál, so štatisticky stabilnými výsledkami naprieč tromi nezávislými behmi (smerodajná odchýlka 0,16 p. b.).

Oba povinné doplnkové experimenty potvrdili očakávaný smer efektu: augmentácia trénovacích dát zvýšila testovaciu accuracy o 1,8 percentuálneho bodu (86,13 % → 84,31 % bez nej), postupné rozmrazovanie vrstiev backbonu prinieslo výrazne väčší nárast – 6,5 percentuálneho bodu (86,13 % → **92,60 %**). Rozmrazovanie vrstiev sa tak ukázalo ako podstatne účinnejší spôsob zlepšenia tejto úlohy než dátová augmentácia, keďže umožňuje doladiť aj vysokoúrovňové konvolučné príznaky backbonu na konkrétnu doménu jedál, namiesto spoliehania sa výlučne na všeobecné, ImageNet naučené reprezentácie.

GradCAM vizualizácia potvrdila, že model sa pri správnych predikciách sústreďuje na samotné jedlo, zatiaľ čo pri chybách často reaguje na vizuálne zameniteľné alebo okrajové prvky obrazu, čo koreluje so zámenami pozorovanými v kontingenčnej tabuľke (napr. *steak*/*beef_tartare*, *pancakes*/*waffles*).

Ďalšie kroky projektu (nad rámec tejto dokumentácie) zahŕňajú natrénovanie a porovnanie modelov M2 (ResNet50 + CBAM), M3 (ConvNeXt), M4 (vizuálny transformer) a M5 (hybridný model CoAtNet) pri rovnakých parametroch trénovania, aby bolo možné vyhodnotiť vplyv architektúry (attention vrstva, optimalizovaná CNN, transformer, hybridný prístup) na úspešnosť a stabilitu klasifikácie pri rovnakej úlohe.