SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Klasifikácia obrazov jedál pomocou transferového učenia

HNS – Projekt č. 1

2025/2026 Bc. Dominik Kupec

Obsah

Úvod **3**

1 Dáta a ich spracovanie **4**
1.1 Dataset 4
1.2 Rozdelenie na trénovaciu, validačnú a testovaciu množinu 4
1.3 Predspracovanie a augmentácia 4
1.4 Parametre trénovania 5

2 Model M1 – CNN ResNet50 **6**
2.1 Priebeh trénovania a výsledky na testovacích dátach 6
2.2 Vizualizácia rozhodovania – GradCAM 7

3 Model M2 – ResNet50 + CBAM **9**
3.1 Architektúra 9
3.2 Priebeh trénovania a výsledky na testovacích dátach 9
3.3 Vizualizácia rozhodovania – GradCAM 11

4 Vplyv augmentácie trénovacích dát **13**

5 Vplyv postupného rozmrazovania vrstiev **18**

6 Porovnanie modelov M1 a M2 **23**
6.1 Diskusia 25

7 Zhrnutie výsledkov **27**

8 Implementácia **28**

Záver **30**

Úvod

Cieľom projektu je porovnať trénovanie vybraných architektúr konvolučných neurónových sietí, vizuálnych transformerov a hybridných modelov pri riešení úlohy klasifikácie obrazu pomocou transferového učenia (transfer learning). Táto dokumentácia pokrýva prvé dva modely zo zadania:

- **M1** – CNN ResNet50 s transferovým učením,
- **M2** – rovnaký ResNet50 doplnený o attention vrstvu **CBAM** (Convolutional Block Attention Module),

a pre oba modely aj dva doplnkové experimenty, ktoré zadanie vyžaduje aspoň pre jeden model:

- vplyv augmentácie trénovacích dát na úspešnosť klasifikácie,
- vplyv postupného rozmrazovania vrstiev (*gradual unfreezing*) predtrénovanej siete oproti trénovaniu so zamrznutým backbonom.

Ako dataset bol použitý výber z databázy **Food-101** – klasifikácia obrazov jedál. Z pôvodných 101 tried bolo vybraných 15 tried, každá s 1000 obrázkami, spolu 15 000 obrázkov. Dataset bol náhodne rozdelený v pomere 80/10/10 na trénovaciu, validačnú a testovaciu množinu (12 000/1 500/1 500 obrázkov) pri zachovaní rovnakého zastúpenia tried vo všetkých troch množinách.

Každá konfigurácia každého modelu bola trénovaná trikrát a výsledky boli štatisticky vyhodnotené (priemer, smerodajná odchýlka, pri porovnaní M1 a M2 aj Welchov t-test). Pre najlepší beh je zobrazený priebeh trénovania (Loss a Accuracy na trénovacích a validačných dátach), na testovacích dátach bola vyčíslená úspešnosť (Accuracy), presnosť (Precision) a senzitivita (Recall) spolu s kontingenčnou tabuľkou. Pre vybrané testovacie vzorky bola vykonaná vizualizácia rozhodovania siete metódou GradCAM.

1 Dáta a ich spracovanie

1.1 Dataset

Pre klasifikáciu bol použitý výber z databázy jedál **Food-101** (zdroj Kaggle, `food41`). Pôvodná databáza obsahuje 101 tried, podľa zadania („použiť minimálne 10 tried, ktoré sú najviac zastúpené“) bolo vybraných **15 tried**: *beef_tartare, chicken_wings, cup_cakes, donuts, dumplings, french_fries, greek_salad, hot_dog, lasagna, lobster_bisque, pancakes, panna_cotta, pizza, steak, waffles*. Každá trieda obsahuje presne 1000 obrázkov, spolu **15 000 obrázkov**, dataset je teda dokonale vyvážený.

1.2 Rozdelenie na trénovaciu, validačnú a testovaciu množinu

Dataset bol náhodne rozdelený v pomere **80 % / 10 % / 10 %** (stratifikovane podľa triedy, aby malo každé jedlo rovnaké zastúpenie vo všetkých troch množinách):

Tabuľka 1: Veľkosť jednotlivých množín

Množina	Obrázkov spolu	Obrázkov na triedu
Trénovacia	12 000	800
Validačná	1 500	100
Testovacia	1 500	100

Rozdelenie je uložené v `data_split/manifest.csv` s pevne daným náhodným semienkom, takže je reprodukovateľné. Všetky modely a konfigurácie používajú to isté rozdelenie a testovacie dáta neboli pri trénovaní ani pri výbere najlepšej epochy použité (najlepší checkpoint sa vyberá podľa validačnej accuracy).

1.3 Predspracovanie a augmentácia

Všetky obrázky sú pred vstupom do siete zmenšené a orezané na 224×224 px a normalizované strednou hodnotou a smerodajnou odchýlkou datasetu ImageNet (keďže backbone je naň predtrénovaný). Pre validačnú a testovaciu množinu sa používa iba táto deterministická transformácia.

Pre trénovaciu množinu je k dispozícii augmentovaná verzia (`RandomResizedCrop` so škálou 0,7–1,0, horizontálne preklopenie, náhodná rotácia $\pm 15°$, farebný jitter, náhodný autokontrast a `RandomErasing`), ktorá sa používa v základnej konfigurácii oboch modelov a je vypnutá pri experimente bez augmentácie (kapitola 4).

1.4 Parametre trénovania

Podľa zadania sa pri všetkých modeloch aj konfiguráciách používajú rovnaké parametre trénovania, takže rozdiely vo výsledkoch možno pripísať architektúre, resp. skúmanému faktoru:

Tabuľka 2: Parametre trénovania (spoločné pre M1 aj M2)

Parameter	Hodnota
Optimalizátor	AdamW
Learning rate	3×10^{-4}
Weight decay	1×10^{-4}
Veľkosť dávky	128
Počet epoch	30
Strata	CrossEntropyLoss
Presnosť výpočtu	zmiešaná (AMP, float16)
Výber checkpointu	epocha s najvyššou validačnou accuracy
Počet nezávislých behov	3 (semienka 43, 44, 45)

AdamW s learning rate 3×10^{-4} je bežná a robustná voľba pre transferové učenie – dostatočne malý, aby pri rozmrazení vrstiev nepoškodil predtrénované váhy, a zároveň dostatočne veľký, aby sa nová výstupná vrstva naučila za 30 epoch. Veľkosť dávky 128 bola zvolená ako maximum, ktoré sa pri postupnom rozmrazovaní M2 (najnáročnejšia konfigurácia, ∼5,8 GiB) zmestí do pamäte použitej GPU (8 GiB).

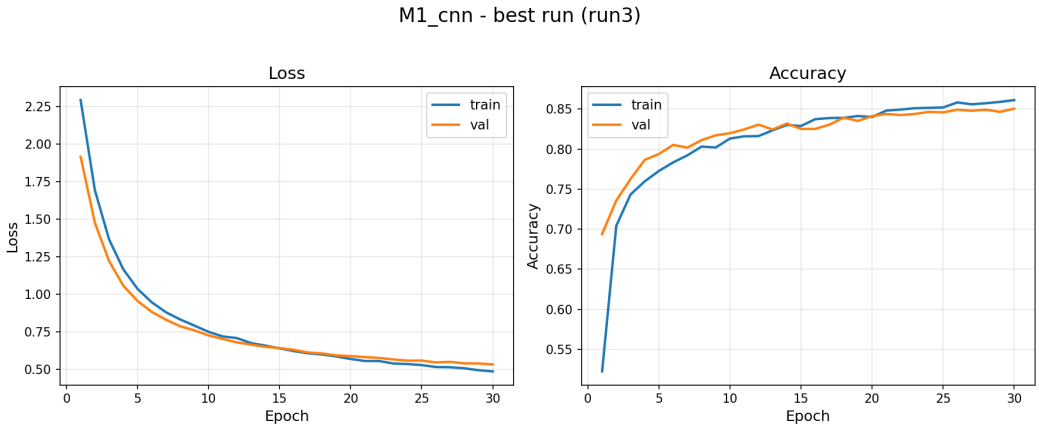
Metriky Precision, Recall a F1 sú počítané ako *makro* priemer cez triedy. Keďže testovacia množina má pre každú triedu presne 100 obrázkov, makro Recall je číselne zhodný s Accuracy. Smerodajná odchýlka je všade počítaná z troch behov (populačná, σ).

2 Model M1 – CNN ResNet50

Ako architektúra CNN bol zvolený **ResNet50**, predtrénovaný na ImageNet (váhy `IMAGENET1K_V2`) – osvedčená architektúra s reziduálnymi spojeniami, ktorá je dostatočne výkonná, a pritom sa (na rozdiel od väčších modelov) dá pri dávke 128 trénovať na bežnej GPU. Výstupná plne prepojená vrstva bola nahradená novou lineárnou vrstvou s 15 výstupmi. V základnej konfigurácii je celý backbone **zamrznutý** – trénuje sa iba nová výstupná vrstva (30 735 parametrov z 23,5 milióna). Táto konfigurácia je referenčná pre porovnanie s modelom M2 aj s postupným rozmrazovaním.

2.1 Priebeh trénovania a výsledky na testovacích dátach

Obr. 1 zobrazuje priebeh trénovania najlepšieho z troch behov. Krivky rastú plynulo a trénovacia a validačná krivka sa takmer prekrývajú – model sa nepreučuje. Keďže sa trénuje iba lineárna vrstva nad zamrznutými príznakmi, model má vzhľadom na 12 000 trénovacích obrázkov malú kapacitu a jeho úspešnosť je obmedzená skôr kvalitou (všeobecných, ImageNet) príznakov než množstvom dát.

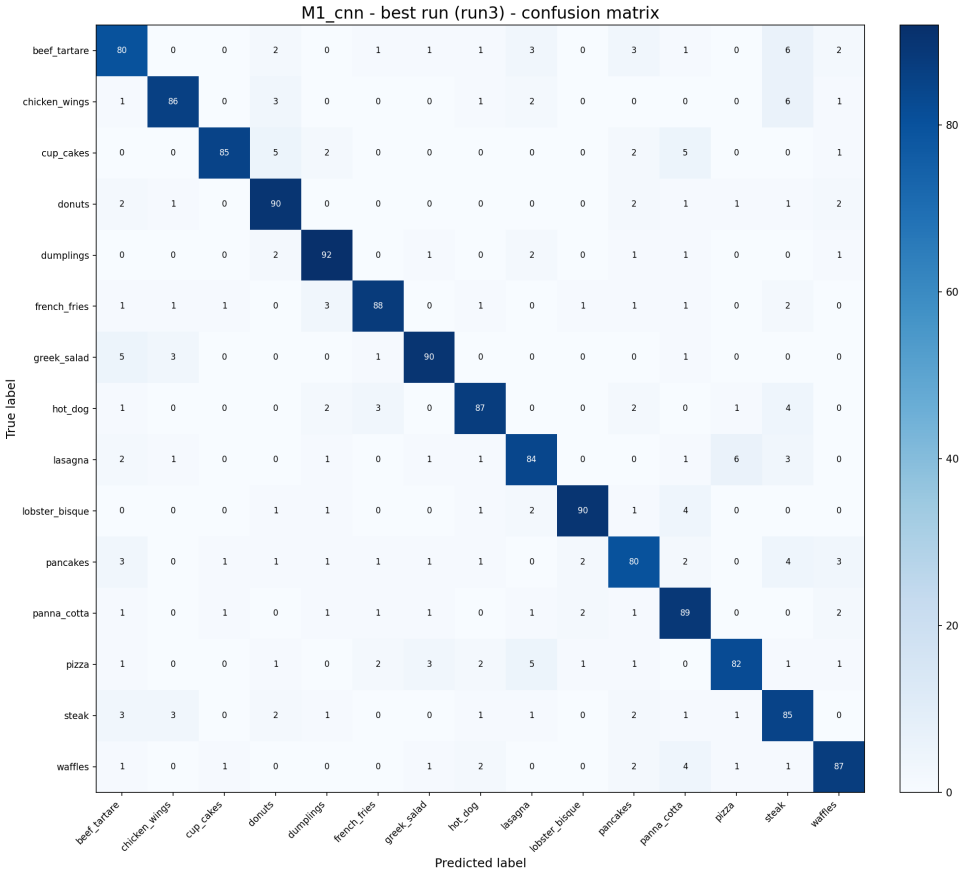


Obr. 1: M1 – priebeh trénovania najlepšieho behu (Loss a Accuracy)

Tabuľka 3: M1 – testovacie metriky (priemer ± smerodajná odchýlka z 3 behov)

Metrika	Hodnota
Accuracy	86,13 ± 0,16 %
Precision	86,43 ± 0,15 %
Recall	86,13 ± 0,16 %
F1	86,19 ± 0,16 %

Nízka smerodajná odchýlka (0,16 p. b.) ukazuje, že výsledok takmer nezávisí od náhodnej inicializácie – pri zamrznutom backbone sa medzi behmi líši iba inicializácia jednej lineárnej vrstvy a poradie dávok.

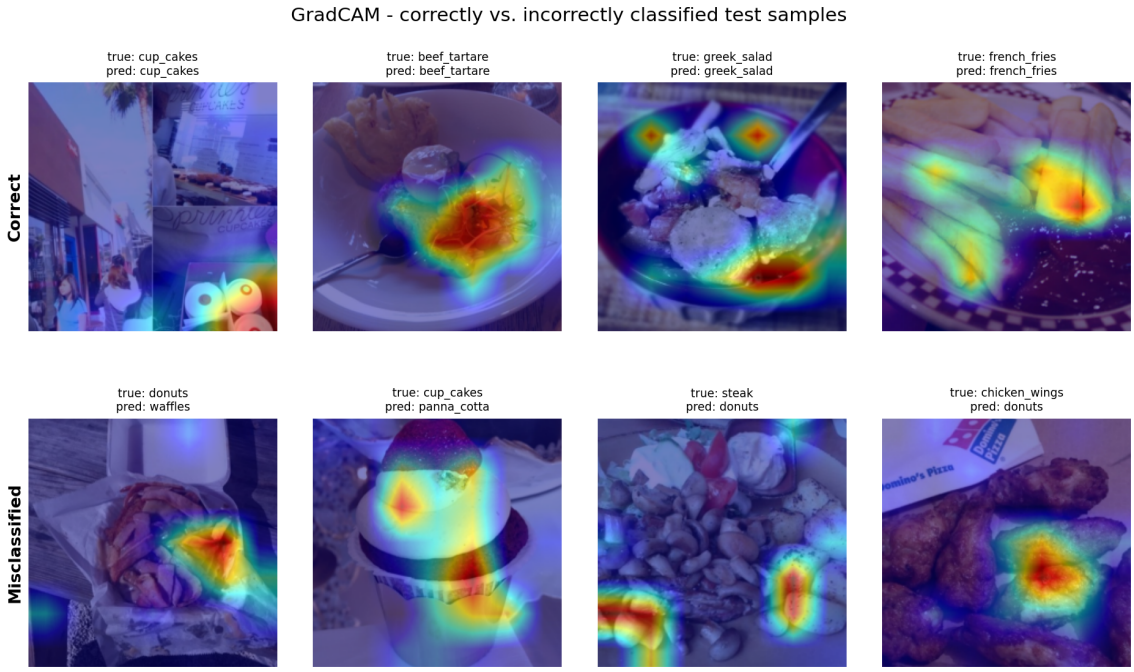


Obr. 2: M1 – kontingenčná tabuľka najlepšieho behu (testovacie dáta)

Súčtom kontingenčných tabuliek všetkých troch behov (300 testovacích obrázkov na triedu) vychádzajú ako najčastejšie zámeny *lasagna* → *pizza* (19-krát), *chicken_wings* → *steak* (17), *beef_tartare* → *steak* (16) a *pizza* → *lasagna* (15). Ide o vizuálne príbuzné jedlá – zapečený syr a paradajková omáčka, resp. hnedé opečené mäso. Najhoršie rozpoznávané triedy sú *pancakes* (recall 80,3 %), *pizza* (80,7 %) a *beef_tartare* (82,3 %), najlepšie *dumplings* (91,7 %), *greek_salad* (91,0 %) a *lobster_bisque* (89,7 %).

2.2 Vizualizácia rozhodovania – GradCAM

Pre náhodne vybrané testovacie vzorky (4 správne a 4 nesprávne klasifikované) bola vykonaná vizualizácia rozhodovania siete metódou **GradCAM**, aplikovanou na výstup posledného konvolučného bloku (`layer4`). Mapa zvýrazňuje oblasti obrazu, ktoré najviac prispeli k predikovanej triede.



Obr. 3: M1 – GradCAM vizualizácia na správne (hore) a nesprávne (dole) klasifikovaných testovacích vzorkách

Pri správne klasifikovaných vzorkách sa aktivácia sústreďuje na samotné jedlo a jeho typickú textúru. Pri chybách sieť často reaguje na časť obrazu, ktorá je vizuálne zameniteľná s inou triedou, alebo na okolie (tanier, prílohu), čo zodpovedá zámenám v kontingenčnej tabuľke.

3 Model M2 – ResNet50 + CBAM

3.1 Architektúra

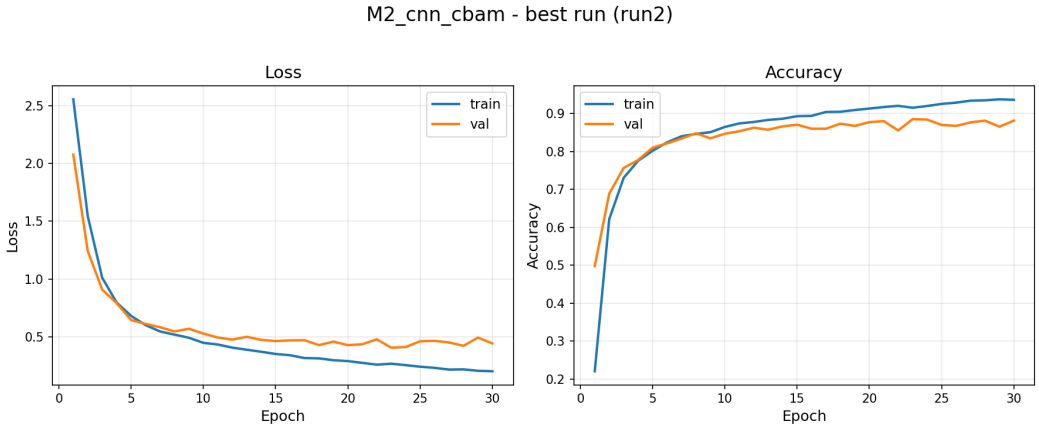
Model M2 je podľa zadania model M1 doplnený o attention mechanizmus **CBAM** (Convolutional Block Attention Module, Woo a kol., 2018). CBAM postupne aplikuje dva typy pozornosti na mapu príznakov $F \in \mathbb{R}^{C \times H \times W}$:

- **kanálová pozornosť** – príznaky sa zredukujú priemerným aj maximálnym poolingom cez priestorové rozmery, prejdú zdieľaným MLP (redukcia $C \to C/16 \to C$) a súčet oboch výstupov po sigmoide váhuje jednotlivé kanály – sieť sa učí, *ktoré* príznaky sú dôležité,
- **priestorová pozornosť** – priemer a maximum cez kanály sa spoja do dvojkanálovej mapy, konvolúcia 7×7 so sigmoidom z nej vytvorí váhu pre každú pozíciu – sieť sa učí, *kde* v obraze sú dôležité oblasti.

Blok CBAM je vložený za každý zo štyroch reziduálnych stupňov ResNet50 (`layer1`–`layer4`, 256, 512, 1024 a 2048 kanálov). Predtrénovaný backbone aj výstupná vrstva sú rovnaké ako pri M1.

Pri zamrznutom backbone sa v M2 trénujú bloky CBAM aj výstupná vrstva – **731 527 trénovateľných parametrov** oproti 30 735 pri M1 (celkovo 24,2 mil. oproti 23,5 mil.). Keďže CBAM je vložený *do* backbonu, gradient musí prejsť spätne aj cez zamrznuté vrstvy `layer2`–`layer4` (ich váhy sa nemenia, ale treba vypočítať gradient vzhľadom na aktivácie). Preto je jedna epocha M2 približne dvakrát pomalšia než pri M1 a model potrebuje viac pamäte GPU.

3.2 Priebeh trénovania a výsledky na testovacích dátach



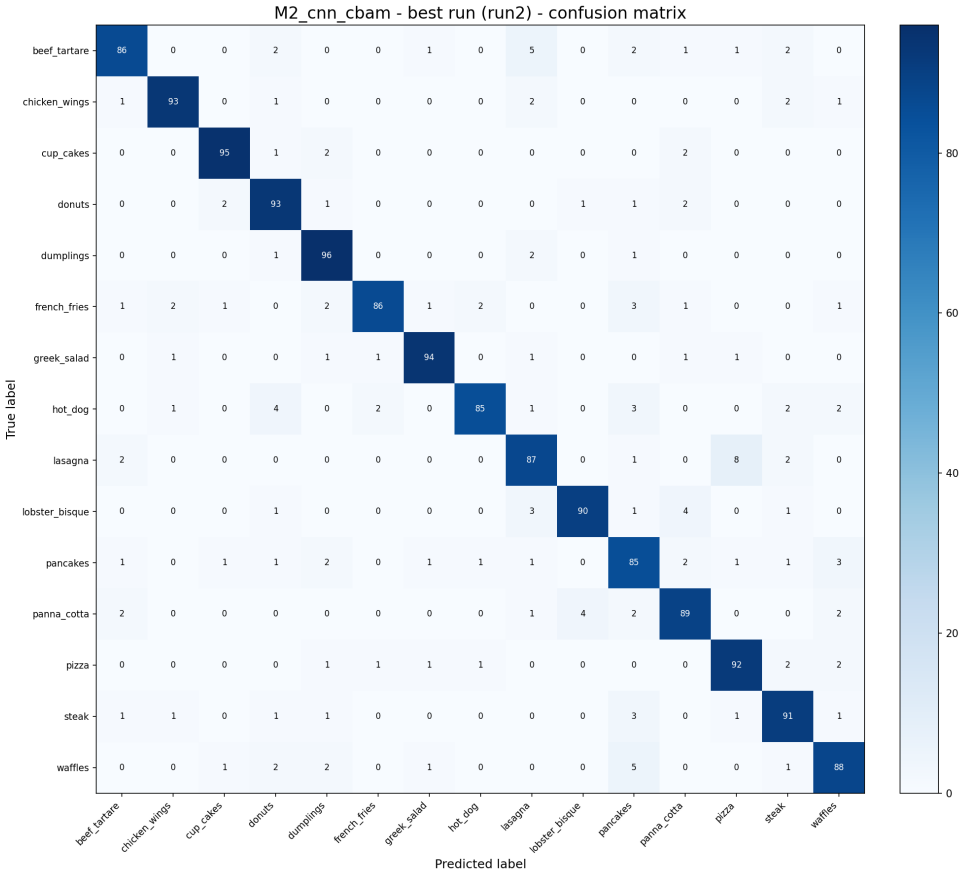
Obr. 4: M2 – priebeh trénovania najlepšieho behu (Loss a Accuracy)

Na rozdiel od M1 začína M2 pomaly – po prvej epoche má validačnú accuracy len ∼15–50 %. Náhodne inicializované bloky CBAM totiž na začiatku náhodne preváhujú predtrénované príznaky, a model sa najskôr musí naučiť pozornosť, ktorá ich nepoškodzuje. Približne od 4. epochy sa M2 vyrovná M1 a potom ho predbieha. Na rozdiel od M1 sa pri M2 postupne otvára rozdiel medzi trénovacou (93,6 %) a validačnou (88,1 %) accuracy – väčší počet trénovateľných parametrov zvyšuje kapacitu, ale aj náchylnosť na preučenie.

Tabuľka 4: M2 – testovacie metriky (priemer ± smerodajná odchýlka z 3 behov)

Metrika	Hodnota
Accuracy	89,07 ± 0,67 %
Precision	89,33 ± 0,64 %
Recall	89,07 ± 0,67 %
F1	89,09 ± 0,67 %

Jednotlivé behy dosiahli 88,73 %, 90,00 % a 88,47 %. Rozptyl je približne štyrikrát väčší ako pri M1 – s viac ako 700 tisíc náhodne inicializovanými parametrami CBAM závisí výsledok viac od inicializácie.

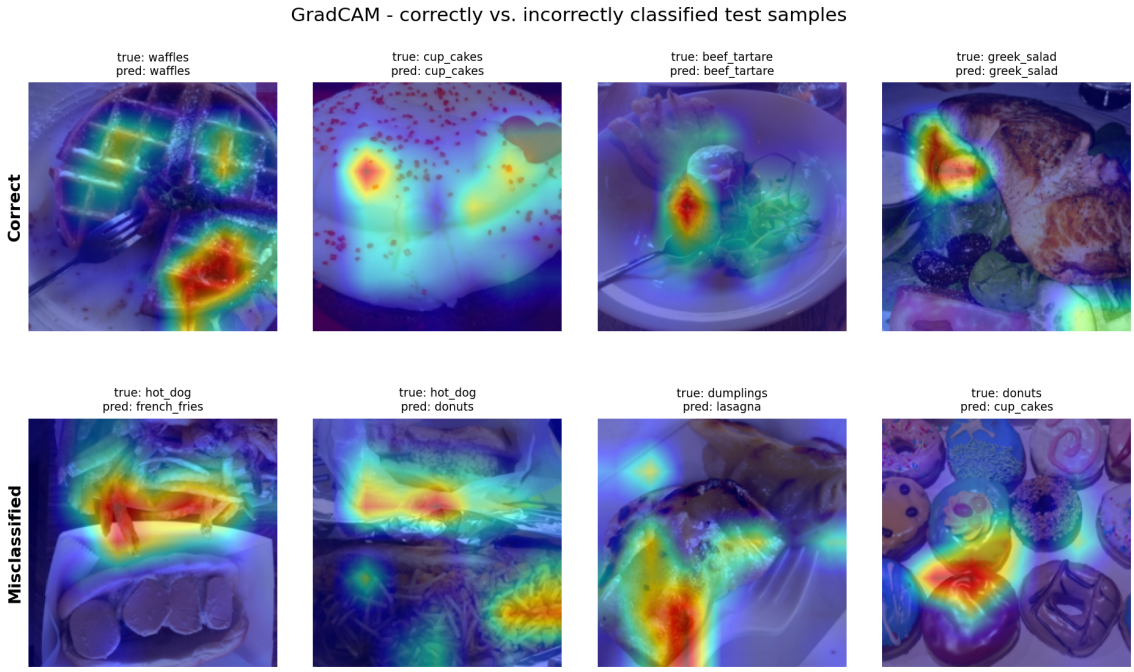


Obr. 5: M2 – kontingenčná tabuľka najlepšieho behu (testovacie dáta)

V súčte troch behov sú najčastejšie zámeny *lasagna* → *pizza* (20-krát, rovnako ako pri M1), *panna_cotta* → *lobster_bisque* (17) a *cup_cakes* → *donuts* (14). Zámeny mäsových jediel za *steak*, typické pre M1, sa výrazne zmenšili. Najhoršie rozpoznávaná trieda je *steak* (85,0 %), najlepšie *greek_salad* (95,7 %) a *dumplings* (94,7 %).

3.3 Vizualizácia rozhodovania – GradCAM

Pri M2 je GradCAM aplikovaný na výstup posledného bloku CBAM (`cbam4`), teda na príznaky `layer4` po zohľadnení pozornosti – práve tie vstupujú do klasifikátora.



Obr. 6: M2 – GradCAM vizualizácia na správne (hore) a nesprávne (dole) klasifikovaných testovacích vzorkách

Pri správnych predikciách sa aktivácia sústreďuje na charakteristické časti jedla (mriežka wafle, poleva cupcaku). Chyby sú dobre interpretovateľné: pri hot dogu klasifikovanom ako *french_fries* sa model pozerá na hranolky položené na párku, pri šiškách klasifikovaných ako *cup_cakes* na zdobenú polevu, ktorá je typická pre obe triedy. Chyby teda vznikajú hlavne pri obrázkoch, ktoré naozaj obsahujú prvky inej triedy.

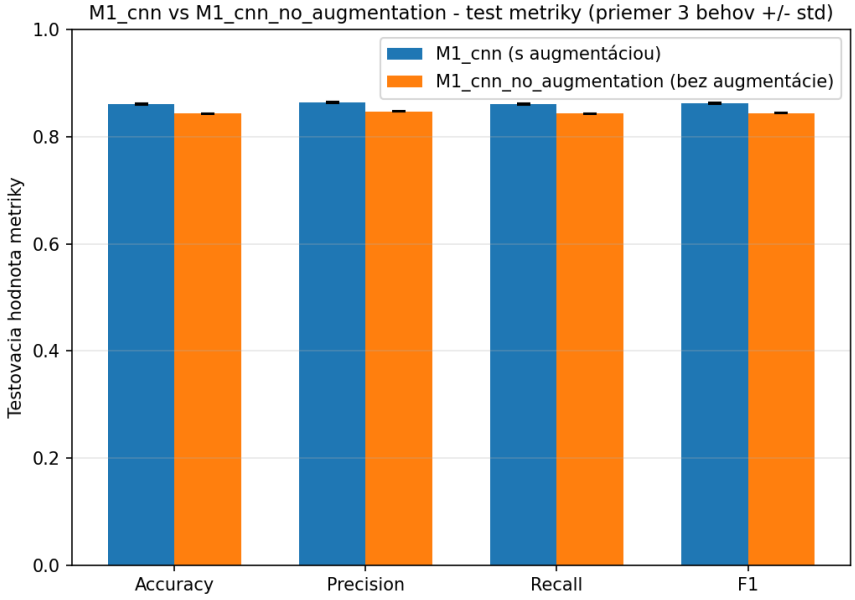
4 Vplyv augmentácie trénovacích dát

Podľa zadania („aspoň pre jeden model ukážte vplyv augmentácie na úspešnosť klasifikácie“) bola pre oba modely porovnaná základná konfigurácia s augmentáciou a konfigurácia bez augmentácie. Ostatné parametre trénovania (Tabuľka 2) zostali nezmenené.

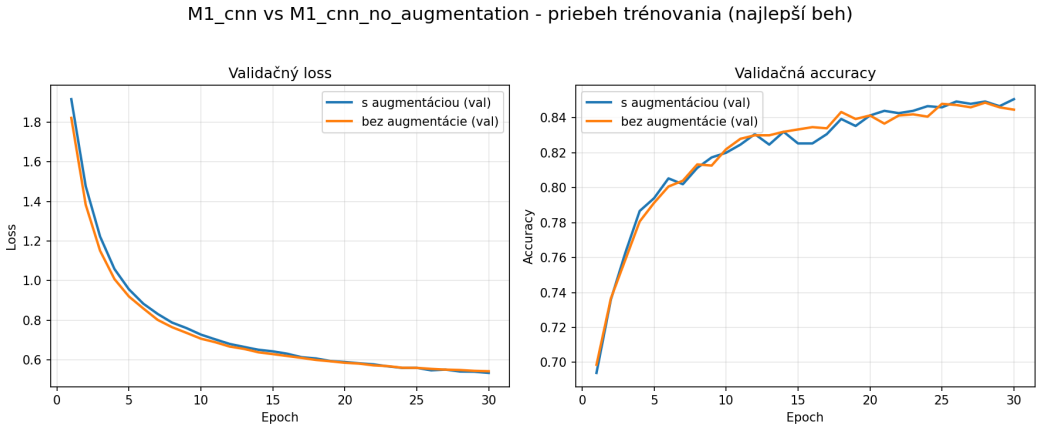
Tabuľka 5: Vplyv augmentácie – testovacie metriky (priemer ± std z 3 behov)

	M1		M2	
	s augm.	bez augm.	s augm.	bez augm.
Accuracy	**86,13 ± 0,16**	84,31 ± 0,06	**89,07 ± 0,67**	85,53 ± 0,52
Precision	**86,43 ± 0,15**	84,67 ± 0,08	**89,33 ± 0,64**	86,01 ± 0,51
Recall	**86,13 ± 0,16**	84,31 ± 0,06	**89,07 ± 0,67**	85,53 ± 0,52
F1	**86,19 ± 0,16**	84,38 ± 0,07	**89,09 ± 0,67**	85,57 ± 0,48

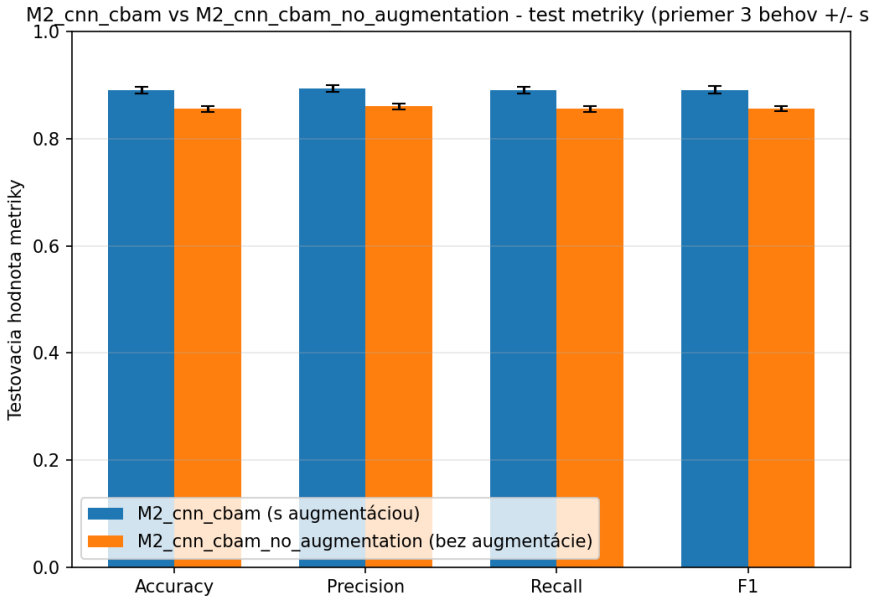
Augmentácia zlepšila testovaciu accuracy pri oboch modeloch – pri M1 o **1,8 p. b.**, pri M2 o **3,5 p. b.** V oboch prípadoch je rozdiel niekoľkonásobne väčší než smerodajná odchýlka, ide teda o systematický efekt.



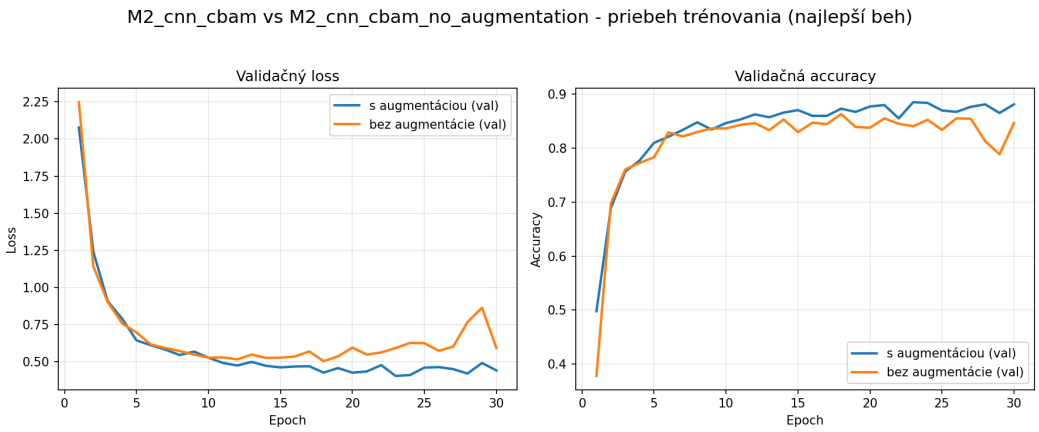
Obr. 7: M1 – vplyv augmentácie na testovacie metriky



Obr. 8: M1 – vplyv augmentácie na priebeh validačného Loss a Accuracy (najlepší beh)



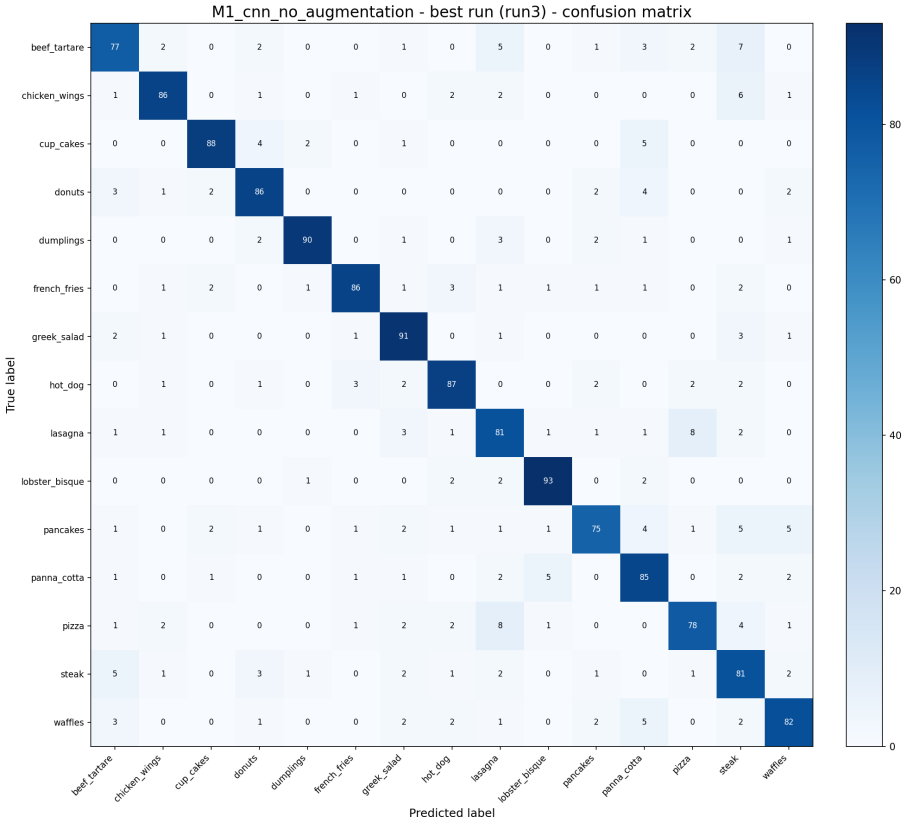
Obr. 9: M2 – vplyv augmentácie na testovacie metriky



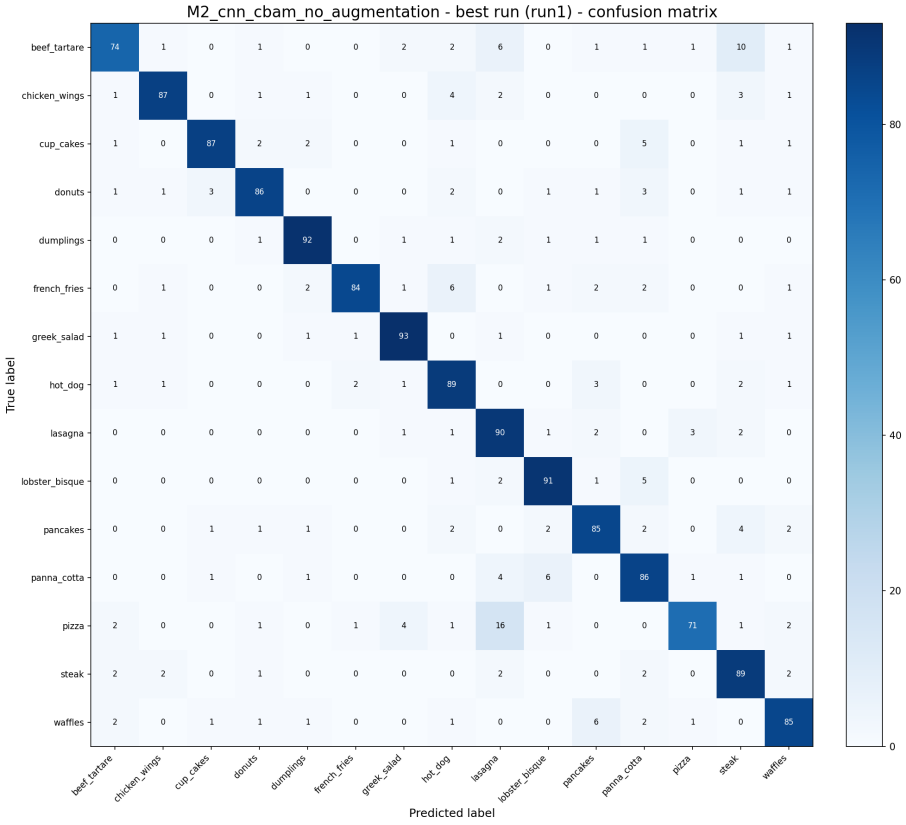
Obr. 10: M2 – vplyv augmentácie na priebeh validačného Loss a Accuracy (najlepší beh)

Pri M1 sú validačné krivky s augmentáciou aj bez nej takmer totožné (Obr. 8) a rozdiel sa prejaví až na testovacích dátach. M1 má iba 30 tisíc trénovateľných parametrov a nepreučuje sa ani bez augmentácie, preto augmentácia nepôsobí ako regularizácia proti preučeniu, ale robí naučený klasifikátor odolnejším voči variáciám vstupu (orezanie, uhol, osvetlenie).

Pri M2 je efekt dvojnásobný. M2 má vďaka blokom CBAM oveľa väčšiu kapacitu a bez augmentácie sa rýchlejšie prispôsobí konkrétnym trénovacím obrázkom – augmentácia tu teda plní aj úlohu klasickej regularizácie. Z toho vyplýva, že väčší model (alebo model s viac trénovateľnými parametrami) z augmentácie profituje viac.



Obr. 11: M1 bez augmentácie – kontingenčná tabuľka najlepšieho behu (testovacie dáta)



Obr. 12: M2 bez augmentácie – kontingenčná tabuľka najlepšieho behu (testovacie dáta)

5 Vplyv postupného rozmrazovania vrstiev

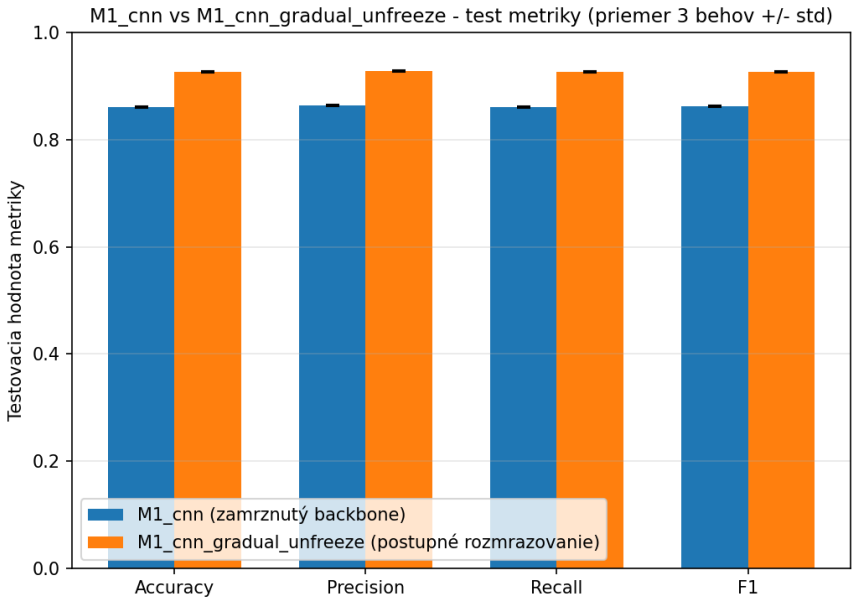
Podľa zadania („aspoň pre jeden model realizujte postupné rozmrazovanie vrstiev predtrénovanej siete“) bola pre oba modely porovnaná základná konfigurácia so **zamrznutým backbonom** a konfigurácia s **postupným rozmrazovaním**.

Rozmrazovanie prebieha v poradí `layer4` → `layer3` → `layer2` → `layer1`, teda od najvyšších, najviac úlohovo-špecifických vrstiev k najnižším, najvšeobecnejším (hrany, textúry). Prvých 6 epoch sa trénuje iba nová výstupná vrstva (a pri M2 bloky CBAM), aby náhodne inicializované vrstvy neposlali do backbonu veľké, nezmyselné gradienty. Potom sa každých 6 epoch rozmrazí jeden stupeň: `layer4` v 7. epoche (+15,0 mil. parametrov), `layer3` v 13. (+7,1 mil.), `layer2` v 19. (+1,2 mil.) a `layer1` v 25. epoche (+0,2 mil.). Vstupná konvolúcia (*stem*) zostáva zamrznutá. Novo rozmrazené parametre sa pridajú do optimalizátora s rovnakým learning rate.

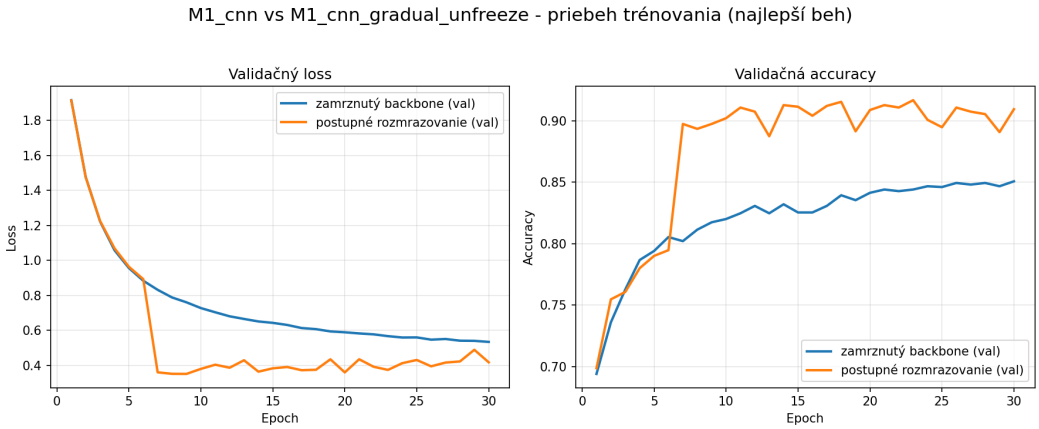
Tabuľka 6: Vplyv postupného rozmrazovania – testovacie metriky (priemer ± std z 3 behov)

	M1		M2	
	zamrznutý	rozmrazovanie	zamrznutý	rozmrazovanie
Accuracy	86,13 ± 0,16	**92,60 ± 0,19**	89,07 ± 0,67	**91,91 ± 0,85**
Precision	86,43 ± 0,15	**92,75 ± 0,15**	89,33 ± 0,64	**92,05 ± 0,79**
Recall	86,13 ± 0,16	**92,60 ± 0,19**	89,07 ± 0,67	**91,91 ± 0,85**
F1	86,19 ± 0,16	**92,61 ± 0,17**	89,09 ± 0,67	**91,93 ± 0,84**

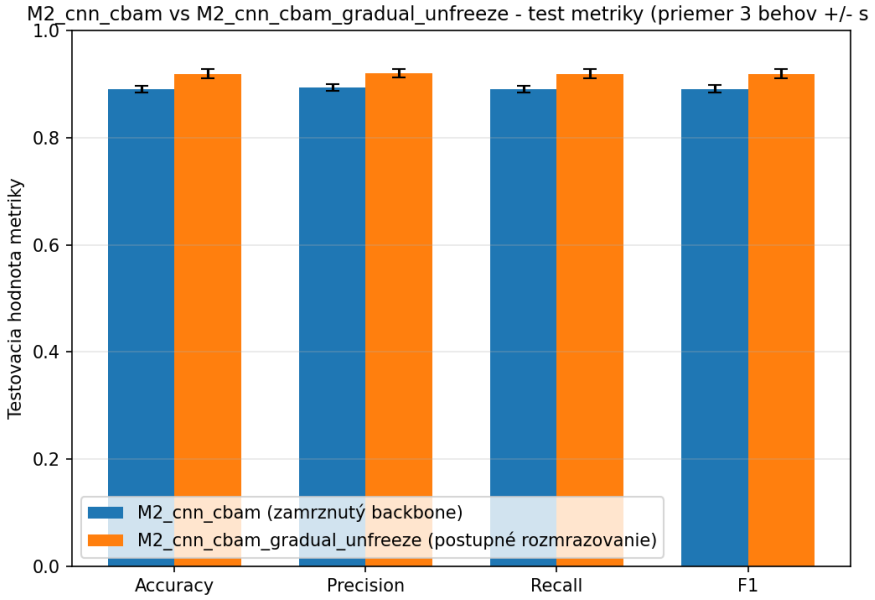
Postupné rozmrazovanie je v tomto projekte najúčinnejšie opatrenie – zvýšilo testovaciu accuracy M1 o **6,5 p. b.** a M2 o **2,8 p. b.**



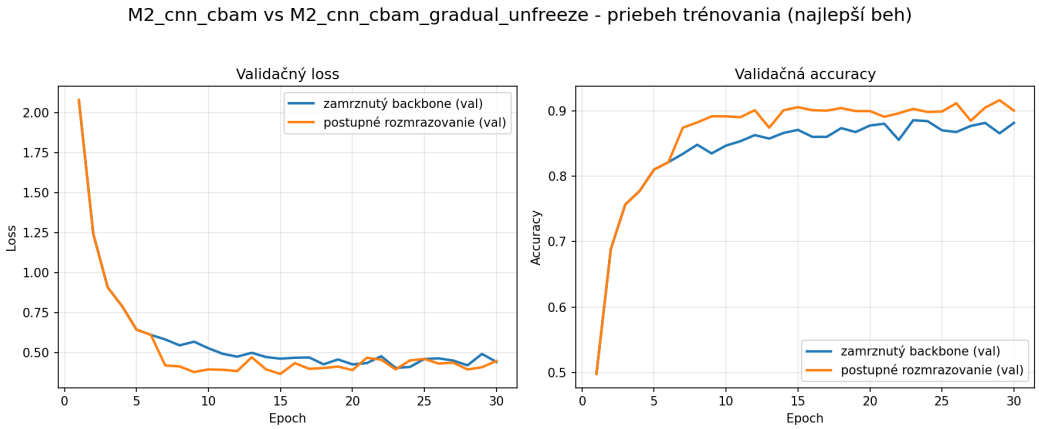
Obr. 13: M1 – vplyv postupného rozmrazovania na testovacie metriky



Obr. 14: M1 – vplyv postupného rozmrazovania na priebeh validačného Loss a Accuracy (najlepší beh)



Obr. 15: M2 – vplyv postupného rozmrazovania na testovacie metriky

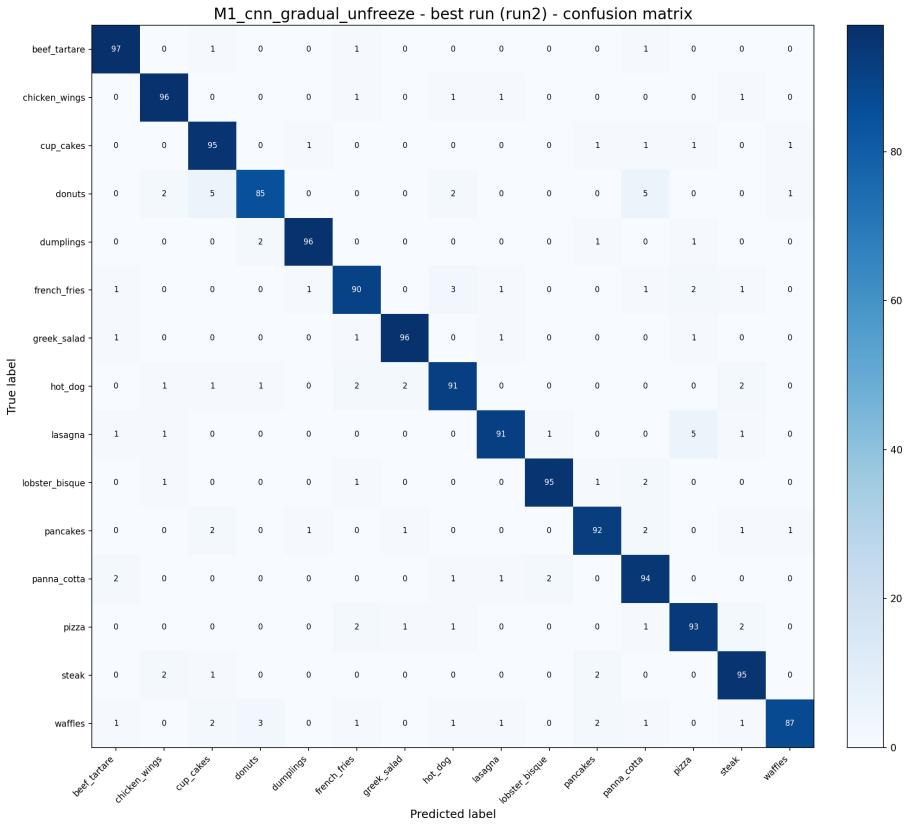


Obr. 16: M2 – vplyv postupného rozmrazovania na priebeh validačného Loss a Accuracy (najlepší beh)

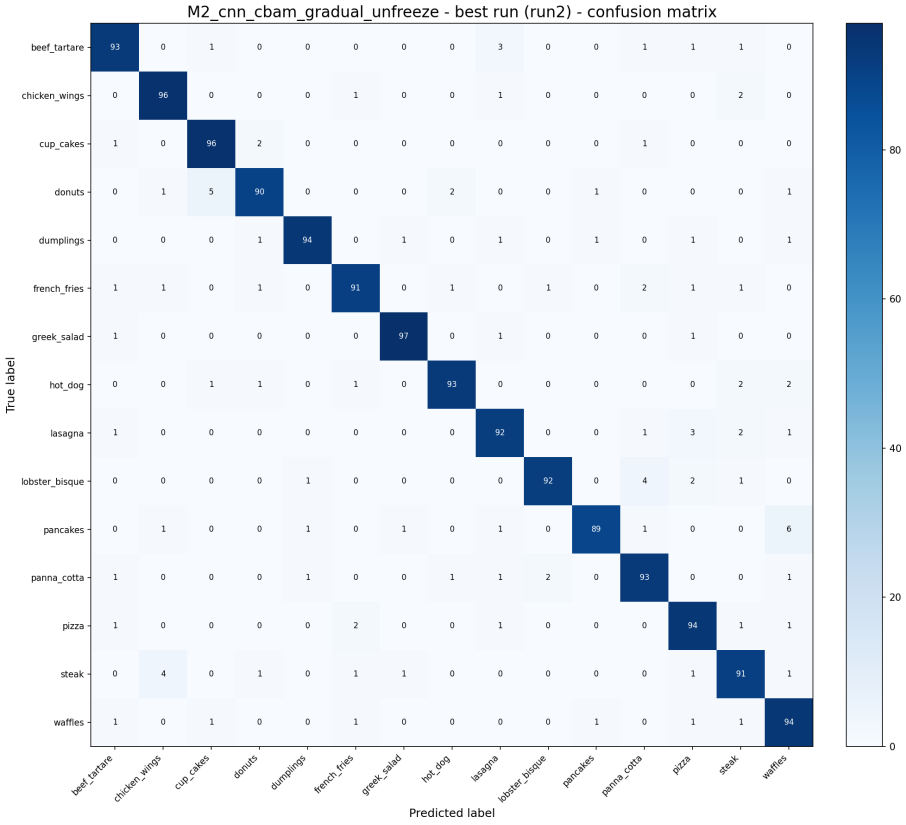
Priebeh validačnej accuracy (Obr. 14 a 16) ukazuje pri oboch modeloch skok v 7. epoche, keď sa rozmrazí `layer4`. Pri M1 klesne validačný loss z ∼0,9 na ∼0,35 a accuracy stúpne z ∼80 % na ∼90 %. Ďalšie stupne (`layer3`–`layer1`) prinášajú už len malé zlepšenie. Rozhodujúce je teda doučiť najvyšší konvolučný stupeň, ktorého príznaky sú najviac špecifické pre pôvodnú úlohu (ImageNet) a najviac profitujú z prispôsobenia na doménu jedál.

Pri M2 je prínos menší. Jedna časť vysvetlenia je, že bloky CBAM už v zamrznutej konfigurácii čiastočne prispôsobujú príznaky backbonu úlohe (prevážením kanálov a

oblastí), takže rozmrazenie má menej čo doháňať. Druhá časť je preučenie: po rozmrazení dosahuje M2 trénovaciu accuracy ∼98 %, zatiaľ čo validačná sa zastaví na ∼90 %. Validačný loss po 8. epoche už neklesá a iba kolíše medzi ∼0,41 a 0,47.



Obr. 17: M1 s postupným rozmrazovaním – kontingenčná tabuľka najlepšieho behu (testovacie dáta)



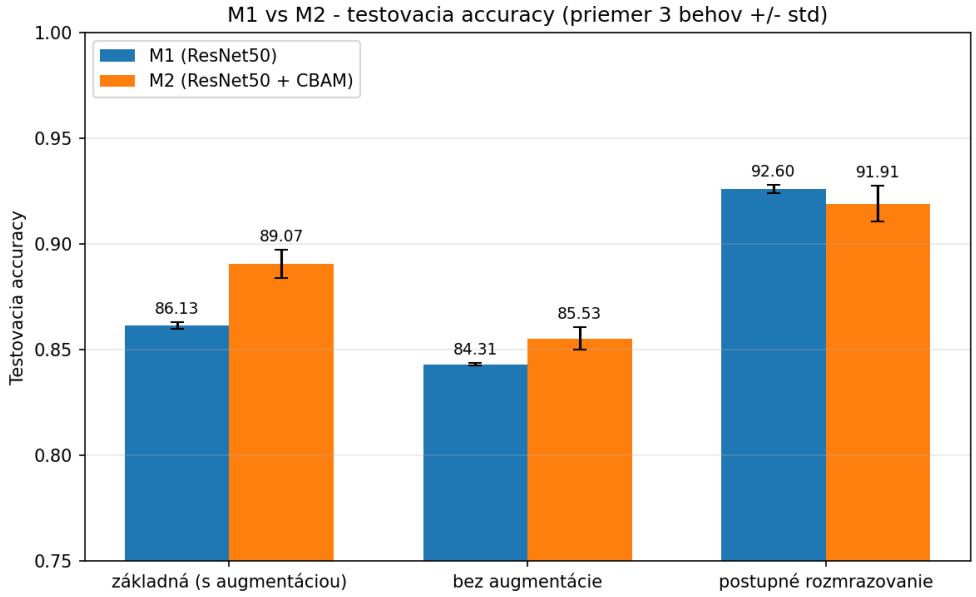
Obr. 18: M2 s postupným rozmrazovaním – kontingenčná tabuľka najlepšieho behu (testovacie dáta)

6 Porovnanie modelov M1 a M2

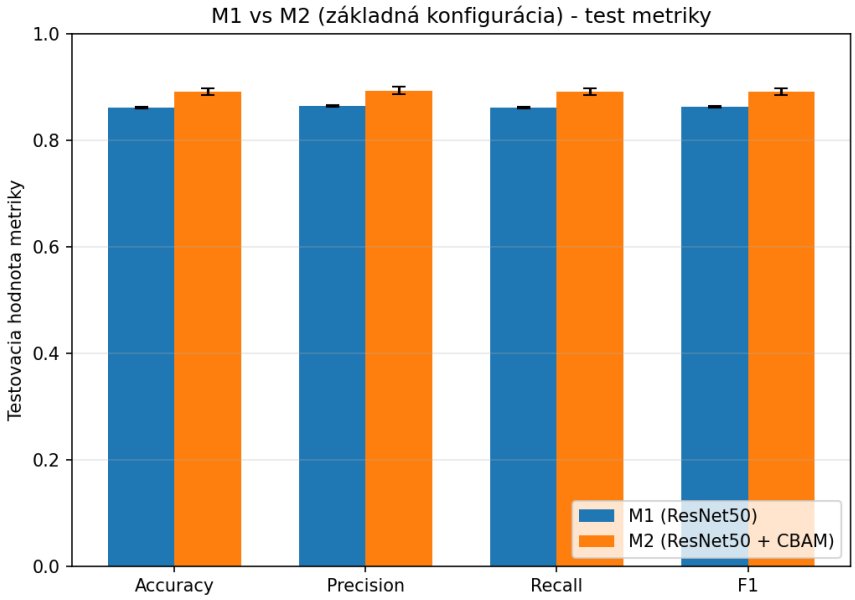
Tabuľka 7 porovnáva oba modely vo všetkých troch konfiguráciách. Štatistická významnosť rozdielu testovacej accuracy bola overená **Welchovým t-testom** (dvojvýberový t-test bez predpokladu zhodných rozptylov) nad tromi behmi každého modelu. Pri iba troch behoch má test malú silu, preto hodnotu p treba chápať ako orientačnú.

Tabuľka 7: Porovnanie M1 a M2 – testovacia accuracy (priemer ± std z 3 behov) a Welchov t-test

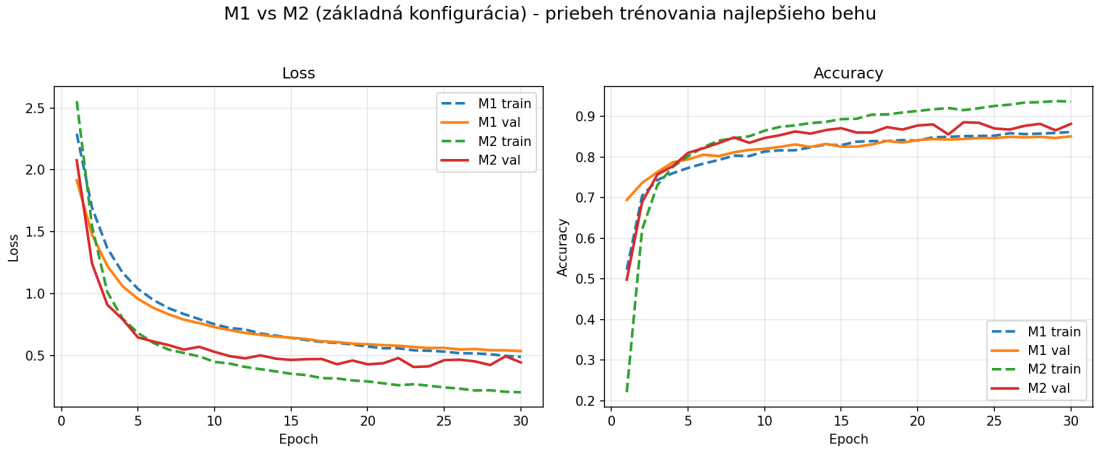
Konfigurácia	M1	M2	Rozdiel M2−M1	p	Významný ($\alpha = 0{,}05$)
Základná (s augm.)	86,13 ± 0,16	**89,07 ± 0,67**	+2,93	0,020	áno
Bez augmentácie	84,31 ± 0,06	**85,53 ± 0,52**	+1,22	0,078	nie
Postupné rozmrazovanie	**92,60 ± 0,19**	91,91 ± 0,85	−0,69	0,369	nie



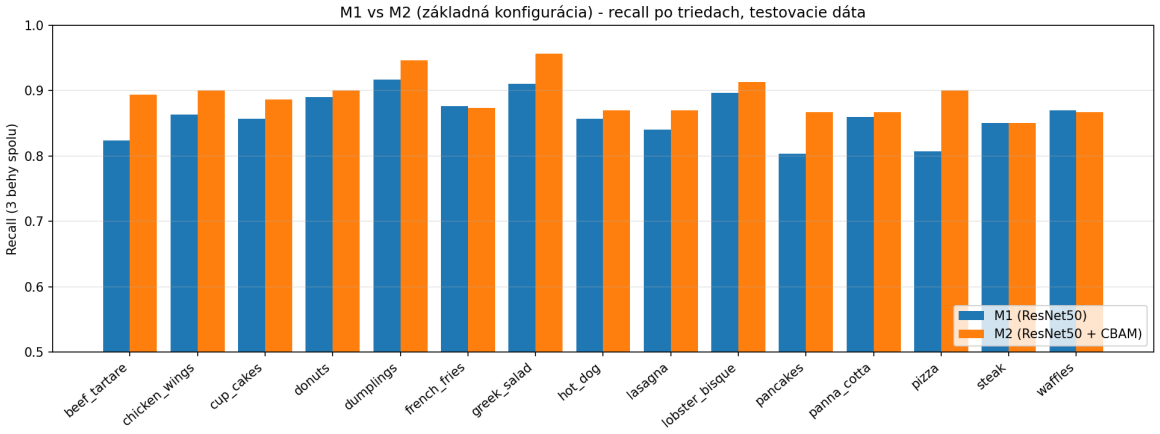
Obr. 19: M1 vs M2 – testovacia accuracy vo všetkých troch konfiguráciách (priemer 3 behov ± std)



Obr. 20: M1 vs M2 (základná konfigurácia) – Accuracy, Precision, Recall a F1



Obr. 21: M1 vs M2 (základná konfigurácia) – priebeh trénovania najlepšieho behu (prerušovane trénovacie, plne validačné dáta)



Obr. 22: M1 vs M2 (základná konfigurácia) – recall jednotlivých tried, súčet troch behov (testovacie dáta)

6.1 Diskusia

Zamrznutý backbone. Pri zamrznutom backbone je M2 štatisticky významne lepší ako M1 (+2,9 p. b., $p = 0{,}020$). Zlepšenie je plošné – M2 má vyšší recall pri 12 z 15 tried, pri jednej rovnaký a pri dvoch o 1 obrázok nižší (Obr. 22). Najviac pomohol pri triedach, kde M1 zlyhával najviac: *pizza* (80,7 → 90,0 %), *beef_tartare* (82,3 → 89,3 %) a *pancakes* (80,3 → 86,7 %). Pri *french_fries*, *steak* a *waffles* sú modely prakticky rovnaké. Pri interpretácii však treba zohľadniť, že M2 nemá len attention mechanizmus, ale aj 24-krát viac trénovateľných parametrov (731 tisíc oproti 30 tisícom). M1 v tejto konfigurácii môže meniť iba lineárnu vrstvu, M2 môže cez CBAM ovplyvniť aj vnútorné príznaky backbonu. Časť zlepšenia preto pochádza zo samotnej väčšej prispôsobiteľnosti, nie nutne z mechanizmu pozornosti ako takého.

Bez augmentácie. Bez augmentácie je M2 stále lepší (+1,2 p. b.), rozdiel však nie je štatisticky významný ($p = 0{,}078$). Väčšia kapacita M2 sa bez augmentácie čiastočne minie na prispôsobenie sa trénovacím obrázkom.

Postupné rozmrazovanie. Keď sa rozmrazí aj backbone, oba modely majú k dispozícii desiatky miliónov trénovateľných parametrov a výhoda M2 zanikne – M1 je dokonca o 0,7 p. b. lepší, rozdiel však nie je významný ($p = 0{,}37$). Pri plnom doladení siete teda CBAM na tomto datasete neprináša merateľné zlepšenie, zato zvyšuje náchylnosť na preučenie a rozptyl výsledkov.

Stabilita a výpočtová náročnosť. M2 má vo všetkých konfiguráciách 4- až 9-krát väčšiu smerodajnú odchýlku než M1 (0,5–0,85 oproti 0,06–0,19 p. b.). Výsledok M2 teda závisí viac od náhodnej inicializácie blokov CBAM. Trénovanie M2 trvalo približne 2,2-krát dlhšie (Tabuľka 8), pretože gradient musí prechádzať cez backbone aj pri

zamrznutých váhach. Časy sú orientačné – počas trénovania M2 bola GPU čiastočne zdieľaná s inými procesmi, čo je vidieť aj na rozdielnych časoch jednotlivých behov postupného rozmrazovania (23 až 39 minút).

7 Zhrnutie výsledkov

Tabuľka 8: Súhrnné porovnanie všetkých konfigurácií M1 a M2 (priemer ± std z 3 behov, testovacie dáta)

Model	Konfigurácia	Accuracy	Precision	Recall	Čas (3 behy)
M1	základná (s augm.)	86,13 ± 0,16	86,43 ± 0,15	86,13 ± 0,16	0:29:50
M1	bez augmentácie	84,31 ± 0,06	84,67 ± 0,08	84,31 ± 0,06	0:27:14
M1	postupné rozmraz.	**92,60 ± 0,19**	**92,75 ± 0,15**	**92,60 ± 0,19**	0:44:10
M2	základná (s augm.)	89,07 ± 0,67	89,33 ± 0,64	89,07 ± 0,67	1:06:25
M2	bez augmentácie	85,53 ± 0,52	86,01 ± 0,51	85,53 ± 0,52	1:04:46
M2	postupné rozmraz.	91,91 ± 0,85	92,05 ± 0,79	91,91 ± 0,85	1:36:38

Najlepší výsledok dosiahol **M1 s postupným rozmrazovaním (92,60 %)**, ktorý je zároveň najstabilnejší a výrazne rýchlejší ako porovnateľná konfigurácia M2. Poradie vplyvu skúmaných faktorov je pri oboch modeloch rovnaké: postupné rozmrazovanie > augmentácia. Attention vrstva CBAM priniesla štatisticky významné zlepšenie iba pri zamrznutom backbone s augmentáciou. Pri rozmrazenom backbone významné zlepšenie nepriniesla.

8 Implementácia

Projekt je napísaný v Pythone (PyTorch, torchvision, pytorch-grad-cam, pandas, matplotlib, scikit-learn, SciPy). Kód v priečinku `src/` je štruktúrovaný takto:

Tabuľka 9: Štruktúra zdrojových súborov

Súbor	Obsah
`config.py`	centrálna konfigurácia (cesty, split, hyperparametre)
`data_preprocessing/split_dataset.py`	rozdelenie datasetu 80/10/10
`data_preprocessing/dataset.py`	`Dataset`/`DataLoader` z manifestu
`data_preprocessing/transforms.py`	augmentované a neaugmentované transformácie
`models/M1_CNN_ResNet50.py`	architektúra M1
`models/M2_CNN_ResNet50_CBAM.py`	architektúra M2 (ResNet50 + CBAM)
`engine.py`	spoločná tréningová/evaluačná slučka, rozvrh rozmrazovania
`experiment.py`	3 behy, ukladanie metrík, grafov a checkpointov
`evaluation.py`	metriky, kontingenčná tabuľka, štatistiky behov
`plots.py`	grafy priebehu trénovania a kontingenčných tabuliek
`gradcam.py`	GradCAM vizualizácia
`M1_ResNet50_Train/train_m1*.py`	M1: základná, bez augm., rozmrazovanie
`M1_ResNet50_Train/gradcam_m1.py`	GradCAM pre najlepší beh M1
`M2_ResNet_CBAM/train_m2*.py`	M2: základná, bez augm., rozmrazovanie
`M2_ResNet_CBAM/gradcam_m2.py`	GradCAM pre najlepší beh M2
`summarize_results.py`	súhrnná tabuľka konfigurácií každého modelu
`compare_ablations.py`	augmentácia a rozmrazovanie voči základnej konfigurácii
`compare_M1_M2.py`	porovnanie M1 a M2, Welchov t-test

Všetky konfigurácie využívajú tú istú tréningovú a evaluačnú infraštruktúru (`engine.py`, `experiment.py`). Líšia sa iba funkciou, ktorá vytvorí model, a parametrami `augment_train` a `unfreeze_schedule`, takže výsledky sú priamo porovnateľné. Výsledky sú v priečinku `Results/` rozdelené podľa modelu:

- `Results/M1_CNN/` – konfigurácie `M1_cnn`, `M1_cnn_no_augmentation`, `M1_cnn_gradual_unfreeze` porovnania v `comparisons/` a súhrn `results_summary.md`,
- `Results/M2_CNN_CBAM/` – analogicky `M2_cnn_cbam`, `M2_cnn_cbam_no_augmentation`, `M2_cnn_cbam_gradual_unfreeze`, `comparisons/` a `results_summary.md`,
- `Results/M1_vs_M2/` – porovnanie oboch modelov (tabuľka s t-testom a grafy).

Každá konfigurácia obsahuje pre každý beh (`run1`–`run3`) históriu trénovania (`history.csv`), kontingenčnú tabuľku (CSV aj PNG) a graf priebehu trénovania. Na úrovni konfigurácie je súhrn troch behov (`summary.json`), grafy najlepšieho behu a kompletný výpis

trénovania (`training_log.txt`). Checkpointy (`best.pt`, ∼90 MB) sa kvôli veľkosti neukladajú do gitu. Dajú sa znova vytvoriť spustením trénovacích skriptov.

Záver

V prvej fáze projektu boli natrénované a vyhodnotené modely M1 (ResNet50) a M2 (ResNet50 + CBAM) na 15-triednej klasifikácii jedál, každý v troch konfiguráciách a s troma nezávislými behmi.

V základnej konfigurácii (zamrznutý backbone, augmentácia) dosiahol M1 testovaciu accuracy **86,13 %** a M2 **89,07 %**. Tento rozdiel je štatisticky významný (Welchov t-test, $p = 0{,}020$). Attention vrstva CBAM umožnila modelu prispôsobiť zamrznuté ImageNet príznaky doméne jedál a zlepšila najmä triedy, v ktorých M1 zlyhával (pizza, beef_tartare, pancakes). Je to však aj za cenu 24-krát viac trénovateľných parametrov, približne dvojnásobného času trénovania a väčšieho rozptylu medzi behmi.

Oba doplnkové experimenty potvrdili očakávaný smer vplyvu pri oboch modeloch:

- **augmentácia** zvýšila accuracy o 1,8 p. b. (M1) a 3,5 p. b. (M2) – model s väčšou kapacitou z nej profituje viac,
- **postupné rozmrazovanie vrstiev** zvýšilo accuracy o 6,5 p. b. (M1) a 2,8 p. b. (M2) a bolo najúčinnejším opatrením v celom projekte.

Po postupnom rozmrazení backbonu sa výhoda CBAM stráca: M1 dosiahol **92,60 %** a M2 91,91 % a rozdiel nie je významný ($p = 0{,}37$). Najlepším modelom tejto fázy je preto **M1 s postupným rozmrazovaním** – je najpresnejší, najstabilnejší (std 0,19 p. b.) a trénuje sa výrazne rýchlejšie ako M2. Záver pre praktické použitie je, že attention mechanizmus CBAM má zmysel hlavne vtedy, keď sa backbone nedá alebo nechce doladiť (napr. pre obmedzené výpočtové prostriedky). Pri plnom doladení siete je jednoduchší model rovnako dobrý.

GradCAM vizualizácia pri oboch modeloch ukázala, že sa sieť pri správnych predikciách sústreďuje na charakteristické časti jedla. Chyby vznikajú najmä pri obrázkoch, ktoré naozaj obsahujú prvky inej triedy (hranolky na hot dogu, poleva na šiškách) alebo pri vizuálne príbuzných jedlách (lasagna a pizza).

Ďalšie kroky projektu zahŕňajú natrénovanie modelov M3 (ConvNeXt), M4 (vizuálny transformer) a M5 (hybridný model CoAtNet) pri rovnakých parametroch trénovania a ich porovnanie s M1 a M2.